



Estudio exploratorio de modelos de aprendizaje automático para la predicción temprana de shock hemorrágico basado en variables preoperatorias e intraoperatorias en pacientes de cirugía mayor no cardíaca

Proyecto de Grado

Autores:

Cristian Eduardo Botina Carpio
Juan Manuel Marín Angarita
Óscar Andrés Gómez Lozano

Tutores:

Ángela Villota Gómez

Universidad Icesi

Facultad Barberi de Ingeniería, Diseño y Ciencias Aplicadas
Ingeniería de Sistemas
Santiago De Cali
2025

Índice

Lista de acrónimos	4
Glosario de términos	7
Índice de tablas	8
1. Introducción	9
1.1. Contexto	9
1.2. Formulación del problema	10
1.3. Impacto del proyecto	11
1.4. Objetivo General	11
1.5. Objetivos Específicos	12
2. Marco Teórico	13
2.1. Shock hemorrágico: definición, fisiopatología y clasificación	13
2.2. Inteligencia artificial en predicción clínica	14
2.3. Interpretabilidad de modelos: SHAP y LIME	15
2.4. Estándares de reporte: TRIPOD	16
3. Estado del Arte	17
3.1. Modelo predictivo para hemorragia pospancreatectomía	17
3.2. Modelo predictivo para accidente cerebrovascular perioperatorio	17
3.3. Predicción del recuperación de shock hemorrágico severo usando re- gresión logística	18
3.4. Modelos multimodales para pronóstico en UCI	18
3.5. Limitaciones de los modelos predictivos clínicos	18
3.6. Síntesis y brecha de conocimiento	19
4. Metodología	21
4.1. Fases metodológicas	21
4.2. Recopilación de limitaciones del estudio	24

5. Desarrollo de la propuesta	25
5.1. Comprensión y preparación de los datos	25
5.1.1. Variable objetivo	27
5.1.2. Variables continuas	27
5.1.3. Variables booleanas	29
5.2. Discriminación inicial de la relevancia de las características sobre la VO	37
5.3. Estrategia experimental	39
5.4. Experimento 1: Baseline	39
5.5. Experimento 2: Agregaciones	40
5.6. Experimento 3: Categorizaciones	41
5.7. Experimento 4: Pruning	42
5.7.1. Comparativa complementaria en pruning	44
5.8. Experimento 5: Hiperparametros	44
5.8.1. Comparativa final: Random Forest vs Decision Tree	46
5.8.2. Estructura e interpretacion del arbol de decision	48
5.8.3. Comparativas visuales de la comparación final de modelos . . .	49
5.9. Evolucion global y cierre de fase experimental	51
6. Construcción de un Pipeline Parametrizado	52
6.1. Evaluación de plataformas de procesamiento	52
6.2. Control de la escalabilidad en la experimentación	52
6.3. Orquestación y reproducibilidad mediante Apache Airflow	53
6.4. Desacoplamiento mediante el patrón Factory y archivos YAML	53
6.5. Organización de reportes y resultados	54
6.6. Interfaz de usuario para la validación de configuraciones	54
6.7. Descripción de la interfaz Streamlit	55
7. Conclusiones y futuro trabajo	59
7.1. Conclusiones	59
7.2. Conclusiones sobre la arquitectura de software	60
7.3. Trabajo futuro	61

Anexos	63
Árbol de problemas	63
Cronograma	65
Análisis de Participación	65
Anexo tecnico de metricas por modelo	66
Referencias	72

Lista de acrónimos

ACS	Sociedad A mericana de C irujanos (A merican C ollege of S urgeons)
AUC-ROC	Área B ajo la C urva R OC (A rea U nder the R eceiver O perating C haracteristic C urve)
CO	Gasto C ardíaco (C ardiac O utput)
CV	Validación C ruzada (C ross V alidation)
DCS	Cirugía de C ontrol de D año (D amage C ontrol S urgery)
DNN	R edes N euronales P rofundas (D eep N eural N etworks)
DT	Árbol de D ecisión (D ecision T ree)
FC	Frecuencia C ardíaca
FVL	F undación V alle de L ili
GBM	Máquina de R efuerzo de G radiente (G radient B oosting M achine)
IA	Inteligencia A rtificial
IMC	Índice de Masa C orporal
IS	Índice de S hock
KNN	K vecinos más cercanos (K N earest N eighbors)
LightGBM	Máquina de R efuerzo de G radiente L igera (L ight G radient B oosting M achine)
ML	A prendizaje A utomático (M achine L earning)
MSI	Índice de S hock M odificado (M odified S hock I ndex)
NB	N aive B ayes (Clasificador probabilístico basado en el teorema de Bayes)
PAM	P resión A rterial M edia
PAS	P resión A rterial S istólica
PPH	H emorragia P ostpancreatectomía (P ostpancreatectomy H aemorrhage)
RPT	R esistencia P eriférica T otal

SHAP	Explicaciones A ditivas de Shapley (SH apley A dditive ex P lanations)
SMOTE	Técnica de S obremuestreo de M inoría S intética (S ynthetic M inority O ver-sampling T Echnique)
THR	R esucitación H ipotensiva T itulada (T itrated H ypotensive R esuscitation)
TRIPOD	Informe T ransparente de un modelo de p redicción m ultivariable (T ransparent R eporting of a multivariable P rediction model for Individual Prognosis o r D iagnosis)
UCI	Unidad de C uidados I ntensivos
VO	Variable O jetivo
VS	Volumen S anguíneo

Glosario de términos

Cirugía mayor no cardíaca: Procedimientos quirúrgicos extensos, de alta complejidad y duración, realizados fuera del sistema cardiovascular (por ejemplo, abdominales, ortopédicas mayores, oncológicas).

Falla multiorgánica: Condición crítica en la que dos o más órganos vitales (como riñones, hígado, pulmones o corazón) dejan de funcionar adecuadamente, generalmente como consecuencia de un shock no tratado.

Frecuencia cardíaca: Número de contracciones del corazón por minuto. Es un parámetro vital que aumenta (taquicardia) como mecanismo compensatorio ante la pérdida de volumen sanguíneo.

Gasto cardíaco: Volumen total de sangre que el ventrículo izquierdo del corazón bombea hacia la aorta cada minuto. Se calcula como el producto de la frecuencia cardíaca por el volumen sistólico ($CO = FC \times VSistolico$).

Hipovolemia: Estado patológico caracterizado por una reducción significativa del volumen de sangre circulante, que puede llevar a shock si no se corrige.

Hipoperfusión tisular: Disminución del flujo sanguíneo hacia los tejidos, lo que impide el suministro adecuado de oxígeno y nutrientes, y la eliminación de desechos metabólicos. Es la base fisiopatológica del shock.

Intervalo RR: Tiempo transcurrido entre dos ondas R consecutivas en un electrocardiograma. Su variabilidad es un indicador sensible de cambios en la función autonómica y puede anticipar eventos críticos.

Perfusión tisular: Proceso mediante el cual la sangre, rica en oxígeno y nutrientes, es distribuida a través del sistema circulatorio para alcanzar todos los tejidos y órganos del cuerpo.

Resistencia Periférica Total (RPT): Fuerza de oposición que encuentran los vasos sanguíneos (principalmente arteriolas) al flujo de la sangre. Es un determinante clave de la presión arterial junto con el gasto cardíaco.

Shock hemorrágico: Tipo de shock hipovolémico causado específicamente por una pérdida aguda y significativa de volumen sanguíneo, que compromete la perfusión de órganos vitales y puede conducir a la muerte si no se trata.

Taquicardia compensatoria: Respuesta fisiológica adaptativa en la que el corazón aumenta su frecuencia cardíaca para intentar mantener un gasto cardíaco adecuado y, por ende, la perfusión tisular, frente a una disminución del volumen sanguíneo.

Índice de tablas

1.	Clasificación del Shock Hipovolémico según la ACS	13
2.	Estado del arte en modelos predictivos para complicaciones postoperatorias	20
3.	Métricas iniciales del dataset	25
4.	Diccionario de variables del dataset	25
5.	Interpretación del coeficiente de Cohen's d	28
6.	Top 3 modelos por AUC-ROC en el Experimento 1	39
7.	Top 3 modelos por AUC-ROC en el Experimento 2	40
8.	Top 3 modelos por AUC-ROC en el Experimento 3	41
9.	Variables descartadas en feature pruning	43
10.	Top 4 modelos por AUC-ROC en el Experimento 4	43
11.	Ranking de modelos por AUC-ROC en el Experimento 5	45
12.	Comparativa de métricas operativas en el Experimento 5 (Comparación Final de Modelos)	47
13.	Evolucion del mejor AUC-ROC por experimento	51
14.	Resumen de discriminacion y calibracion - Experimento 1 (Baseline) . .	66
15.	Resumen de punto operativo - Experimento 1 (Baseline)	66
16.	Resumen de discriminacion y calibracion - Experimento 2 (Agregaciones)	67
17.	Resumen de punto operativo - Experimento 2 (Agregaciones)	67
18.	Resumen de discriminacion y calibracion - Experimento 3 (Categoriza- ciones)	67
19.	Resumen de punto operativo - Experimento 3 (Categorizaciones)	68
20.	Resumen de discriminacion y calibracion - Experimento 4 (Pruning) . .	68
21.	Resumen de punto operativo - Experimento 4 (Pruning)	68
22.	Resumen de discriminacion y calibracion - Experimento 5 (Hiperpara- metros)	69
23.	Resumen de punto operativo - Experimento 5 (Hiperparametros)	69
24.	Metricas de calibracion - Top 4 modelos Experimento 5	69
25.	Parametros optimos (optimized_params) en Experimento 5	70
26.	Top 3 de importancia de características en Experimentos 2, 3 y 5 . . .	71

1. Introducción

1.1. Contexto

El shock hemorrágico es una falla aguda del sistema circulatorio, causada por una pérdida rápida del volumen sanguíneo, lo que impide mantener niveles suficientes de oxígeno para las funciones de órganos vitales. El shock postoperatorio tiene varios estados que progresan desde etapas compensadas hasta descompensación completa. Según Bonanno [1], estos se dividen en cinco niveles que se basan en la respuesta fisiológica de paciente, donde en el nivel I están las personas que se encuentran en un estado de taquicardia leve y una presión arterial sistólica (PAS) en un rango nominal, mientras que en el nivel III se observa un aumento en la frecuencia cardíaca, disminución del PAS y pérdida de consciencia. La clasificación enfatiza el momento óptimo para intervenciones específicas (DCS y THR) en lugar de depender de umbrales fijos, de este modo adaptándose a datos del paciente como edad y comorbilidades. La mortalidad en etapas avanzadas (IV-V) se produce cuando se alcanza hipotensión extrema y signos evidentes de descompensación como pérdida absoluta de la consciencia, paro cardíaco, falla multiorgánica, etc. La detección temprana es crítica, ya que cada minuto de retraso aumenta el riesgo de muerte [14].

Actualmente el proceso de detección del shock hemorrágico conlleva evaluación completa de parte del personal médico, usando medidas como el índice de shock (IS), cociente que relaciona la taquicardia compensatoria con la caída de la presión arterial [2]. Aunque el IS con punto de corte de 1,11 presenta una sensibilidad del 91,3 % y su versión modificada alcanza el 95,65 % de sensibilidad, ambos tienen limitaciones marcadas que dificultan el proceso de acción:

- **Limitaciones de los índices convencionales:** Los métodos basados exclusivamente en presión arterial pueden no identificar hasta un 8–9 % de casos de hemorragia masiva en sus etapas iniciales [2].
- **Índices predictivos con sensibilidad y especificidad variables:**
 - Shock Index (SI): Sensibilidad 91.3 %, especificidad 79.7 %.
 - Modificado Shock Index (MSI): Sensibilidad 95.7 %, especificidad 75.8 %.
- **Carga cognitiva del personal clínico:** La “ceguera por desviación” y la sobrecarga de información pueden afectar la toma de decisiones clínicas, especialmente en procedimientos prolongados.
- **Enfoque en manifestaciones avanzadas:** Los criterios diagnósticos habituales como la hipotensión se manifiestan en fases relativamente tardías del shock, lo que dificulta la intervención preventiva; no siempre se dispone de información individualizada sobre comorbilidades o características demográficas.

El retraso en la predicción temprana conlleva consecuencias serias que pueden repercutir en la salud del paciente, entre ellas:

- Según [14], en Estados Unidos se registran más de 60.000 muertes anuales relacionadas con hemorragia; a nivel mundial, se estiman alrededor de 1,9 millones de muertes por año, de las cuales aproximadamente 1,5 millones se asocian a trauma físico.
- Aumento de transfusiones, infecciones, fallo multiorgánico y costos económicos.

La inteligencia artificial representa una herramienta complementaria prometedora para la detección temprana del shock hemorrágico, con el potencial de apoyar al equipo clínico en la identificación del denominado “shock subclínico”, en el que “la microcirculación subyacente se ve comprometida a pesar de que las variables de macrocirculación permanecen en rangos normales”. Los sistemas de monitoreo convencionales se centran principalmente en parámetros estáticos como la presión arterial, los cuales pueden mantenerse dentro de límites normales incluso cuando el paciente se aproxima al límite de su capacidad compensatoria, puesto que “cualquier mecanismo compensatorio fisiológico tiene una respuesta máxima finita ante un estrés específico”.

Aunque herramientas como el índice de shock (SI) y el índice de shock modificado (MSI) han contribuido a mejorar la detección, presentan limitaciones en especificidad y no siempre contemplan la variabilidad individual en la respuesta compensatoria. Los modelos de machine learning ofrecen la posibilidad de complementar estos enfoques al integrar múltiples variables clínicas (hematocrito, tiempo quirúrgico, clasificación ASA, entre otros) y analizar sus interacciones complejas, permitiendo identificar patrones que resultan difíciles de procesar de forma simultánea durante la práctica clínica.

Sin embargo, estas soluciones aún enfrentan importantes limitaciones: la mayoría de los estudios existentes utilizan diseños retrospectivos con acceso limitado a datos temporales precisos, dependen de protocolos estandarizados en centros de alta volumetría que limitan su aplicabilidad en entornos menos especializados, y carecen de validación prospectiva en diversos escenarios clínicos. Además, la escasez de estudios prospectivos en el campo representa un obstáculo para la implementación clínica generalizada. La verdadera potencia de estos sistemas no radica en el reemplazo del personal, sino en la capacidad del sistema de generar alertas tempranas con parámetros interpretables y significativos para el tratamiento del paciente.

1.2. Formulación del problema

La detección tardía del shock hemorrágico en pacientes sometidos a cirugías mayores no cardíacas constituye un desafío crítico en la práctica clínica actual. En la mayoría de los casos, la identificación de esta complicación depende de la interpretación clínica del equipo médico y de criterios diagnósticos que frecuentemente se manifiestan en

fases avanzadas de la condición, lo cual limita la capacidad de anticipación y aumenta la variabilidad en la toma de decisiones entre diferentes profesionales. Esta situación se ve agravada por la ausencia de protocolos estandarizados, la dificultad para interpretar cambios sutiles en los signos vitales y las limitaciones humanas en el monitoreo continuo durante procedimientos prolongados.

La consecuencia directa de esta detección tardía es un incremento en la mortalidad y morbilidad postoperatoria, con mayor riesgo de falla multiorgánica, complicaciones asociadas a transfusiones sanguíneas y recuperación prolongada de los pacientes. Asimismo, se generan impactos significativos en los recursos hospitalarios debido al aumento en la necesidad de transfusiones, cirugías adicionales, estancias prolongadas en UCI y sobrecarga del personal médico.

1.3. Impacto del proyecto

El proyecto tiene un impacto en el ámbito clínico, social e institucional. Desde el punto de vista clínico, la implementación del modelo permitirá reducir la mortalidad asociada a complicaciones relacionadas con shock hemorrágico, pues al anticipar este riesgo de forma temprana se puede evitar la falla multiorgánica, mejorando los resultados postoperatorios. Esto a su vez, contribuye al uso más eficiente de los recursos hospitalarios, ya que al disminuir la necesidad de estancias prolongadas en unidades de cuidados intensivos se logra una reducción en los costos, así como una mejor planificación de insumos como sangre y medicamentos.

Además, se promueve la innovación tecnológica en el sistema de salud de Colombia, que fortalece la colaboración entre las áreas de medicina e ingeniería e integra factores individuales del paciente. Esto transforma el paradigma del monitoreo, que actualmente funciona mediante una vigilancia basada en umbrales fijos y la experiencia del profesional de la salud, donde los indicadores no son lo suficientemente claros. Al predecir mediante un modelo el riesgo, se obtiene una estrategia más personalizada, dinámica y anticipatoria, especialmente importante en poblaciones de alto riesgo, donde la tolerancia a la hemorragia es mínima.

1.4. Objetivo General

Realizar una exploración de modelos de aprendizaje automático para la predicción temprana del shock hemorrágico en pacientes sometidos a cirugía mayor no cardíaca, integrando variables clínicas preoperatorias e intraoperatorias y evaluando su interpretabilidad para el apoyo a la toma de decisiones médicas.

1.5. Objetivos Específicos

- a) Identificar y preprocesar las variables clínicas críticas de los periodos preoperatorio e intraoperatorio en la población de cirugía mayor no cardíaca, asegurando la calidad y coherencia del dataset para el análisis exploratorio.
- b) Determinar qué modelos de aprendizaje supervisado presentan mejor desempeño en la detección de eventos hemorrágicos mediante la comparación de diversos algoritmos y métricas de sensibilidad clínica.
- c) Implementar un análisis de interpretabilidad mediante SHAP para identificar la influencia de los factores pre e intraoperatorios en el riesgo de shock, permitiendo una validación transparente por parte de los especialistas.
- d) Construir un pipeline parametrizado y una interfaz funcional en Streamlit que facilite la ejecución de experimentos y la visualización de los factores de riesgo de manera reproducible.

2. Marco Teórico

2.1. Shock hemorrágico: definición, fisiopatología y clasificación

En el contexto clínico, una presión arterial media (PAM) por debajo de 60 mmHg puede comprometer la perfusión tisular, es decir, el suministro de oxígeno a los órganos vitales. La PAM depende del gasto cardíaco (CO) y la resistencia periférica total (RPT), siendo el CO a su vez influenciado por el volumen sanguíneo y la frecuencia cardíaca. Cuando este equilibrio se rompe y se produce hipoperfusión, se desencadena un estado de shock. Según la American College of Surgeons (ACS), el shock se clasifica en cuatro tipos principales: cardiogénico, distributivo, obstructivo e hipovolémico [4]. En particular, el shock hemorrágico es un tipo de shock hipovolémico que se produce por la pérdida de sangre [14], lo que puede llevar a la necrosis de las células tisulares, falla multiorgánica y muerte si no se trata a tiempo.

La clasificación del shock hemorrágico permite evaluar la gravedad de la pérdida sanguínea según los signos clínicos del paciente. La ACS identifica las siguientes 4 clases [4]:

Tabla 1: Clasificación del Shock Hipovolémico según la ACS

Clase	Volumen aprox.	Frecuencia Cardíaca	Presión Arterial	Estado mental
I	<15 %	Normal	Normal	Ansioso
II	15-30 %	100 BPM a 120 BPM	Normal o leve	Inquieto
III	30-40 %	Más de 120 BPM	Sistólica <90mmHg	Confuso
IV	>40 %	Más de 120 BPM	<60mmHg	Inconsciente

En cuanto a la fisiopatología del shock hemorrágico, este sigue una progresión definida. En sus fases iniciales, el sistema cardiovascular activa mecanismos homeostáticos como la taquicardia, vasoconstricción periférica y redistribución del flujo sanguíneo hacia el cerebro y corazón, esto con el fin de compensar la pérdida de sangre. Estos mecanismos, aunque permiten mantener una PAM estable durante las primeras etapas, genera un efecto máscara, donde el paciente parece estar estable hasta que ya se encuentra en una fase crítica. Un dato importante es que los signos clínicos mencionados anteriormente se suelen manifestar solo tras la pérdida de un 30-40 % del volumen circulante, lo que limita su capacidad para la detección temprana, caracterizada por hipotensión arterial, acidosis metabólica, coagulopatía y eventual colapso circulatorio.

Por otro lado, cambios sutiles en parámetros fisiológicos, como el intervalo RR en el electrocardiograma, desaturaciones intermitentes de oxígeno o tendencias en la presión arterial media pueden ser clave para anticipar a la descompensación clínica

por minutos o incluso horas, pero son difíciles de identificar de forma continua por el personal médico, ya sea por sobrecarga cognitiva o fatiga durante procedimientos prolongados y la variabilidad en la interpretación clínica.

2.2. Inteligencia artificial en predicción clínica

La Inteligencia Artificial (IA) aplicada a la predicción clínica se basa en el aprendizaje a partir de datos históricos, mediante modelos que identifican patrones complejos y predicen eventos futuros con un grado de incertidumbre cuantificable. En el contexto del shock hemorrágico, un modelo predictivo asigna una probabilidad de riesgo de que un paciente desarrolle esta condición crítica en los próximos minutos u horas, permitiendo intervenciones tempranas que pueden ser vitales. El aprendizaje automático (ML), ha surgido como una herramienta clave en la medicina predictiva, permitiendo el análisis de grandes volúmenes de datos clínicos para identificar patrones que difícilmente serían vistos por un personal humano, aún con años de experiencia. A diferencia de los modelos estadísticos tradicionales, como regresión logística, los algoritmos de ML pueden manejar relaciones no lineales, lo que los hace mucho más adecuados para el contexto clínico, donde las relaciones son complejas.

Para este fin, se han desarrollado diversos enfoques algorítmicos, cada uno con ventajas y limitaciones específicas según la naturaleza de los datos y los requisitos clínicos:

- **Regresión logística con regularización Lasso:** la regresión logística es un modelo clásico para predicción binaria que estima la probabilidad de un evento mediante una función logística. Sin embargo, su principal limitación radica en la suposición de relaciones lineales entre las variables predictoras y el logaritmo de las probabilidades. Para superar parcialmente esta restricción y mejorar la interpretabilidad, se emplea la variante Lasso (Least Absolute Shrinkage and Selection Operator), que introduce una penalización L1 en la función de pérdida. Esta penalización fuerza a que algunos coeficientes se reduzcan exactamente a cero, lo que equivale a una selección automática de variables relevantes. Este enfoque no solo reduce la complejidad del modelo, sino que también mejora su capacidad de generalización, especialmente en escenarios con alta dimensionalidad o colinealidad entre predictores.
- **K-Nearest Neighbors (KNN):** este algoritmo no paramétrico clasifica o predice un resultado basándose en la similitud entre un nuevo caso y los k casos más cercanos en el espacio de características. Aunque KNN es intuitivo y no requiere suposiciones sobre la forma funcional de las relaciones, su desempeño depende críticamente de la elección de k, la métrica de distancia utilizada y la escala de las variables. En contextos clínicos, donde los datos pueden ser ruidosos o escasos, KNN puede volverse inestable si no se normalizan adecuadamente las variables o

si el número de vecinos no se ajusta con validación cruzada rigurosa. No obstante, su simplicidad lo hace útil como modelo de referencia o en combinación con técnicas de reducción de dimensionalidad.

- **LightGBM (Light Gradient Boosting Machine):** como una implementación eficiente y escalable de los modelos de Gradient Boosting, LightGBM construye árboles de decisión de forma secuencial, donde cada nuevo árbol se entrena para corregir los errores residuales del modelo acumulado hasta ese punto. A diferencia de otros algoritmos de boosting, LightGBM utiliza una estrategia de crecimiento basada en hojas (leaf-wise) en lugar de niveles (level-wise), lo que le permite alcanzar mayor precisión con menor número de hojas. Además, incorpora técnicas como el muestreo basado en gradientes (Gradient-based One-Side Sampling, GOSS) y el agrupamiento exclusivo de características (Exclusive Feature Bundling, EFB), lo que reduce drásticamente el tiempo de entrenamiento y el uso de memoria sin sacrificar rendimiento. En entornos clínicos con grandes volúmenes de datos heterogéneos como señales vitales en tiempo real, laboratorios y antecedentes médicos, LightGBM ha demostrado ser particularmente eficaz para capturar interacciones no lineales y efectos de umbral, superando con frecuencia a modelos más simples en métricas de discriminación y calibración.

2.3. Interpretabilidad de modelos: SHAP y LIME

Dado que la implementación de modelos de ML supone el uso de técnicas de caja negra, se utilizan técnicas para facilitar la interpretación:

- **SHapley Additive exPlanations (SHAP):** SHAP es una técnica de interpretabilidad basada en la teoría de juegos cooperativos, específicamente en los valores de Shapley [?]. Su objetivo es cuantificar la contribución de cada variable (feature) a una predicción individual, distribuyendo equitativamente el valor de la predicción entre las características del modelo.

¿Por qué se utiliza en contextos médicos? En aplicaciones clínicas, no es suficiente que un modelo tenga un alto rendimiento predictivo; es fundamental que los profesionales de salud puedan comprender *por qué* el modelo toma una decisión. SHAP permite desglosar cada predicción en contribuciones individuales de cada variable, lo que facilita la validación médica, aumenta la confianza del equipo clínico y permite detectar posibles sesgos algorítmicos. Además, SHAP proporciona explicaciones tanto globales (importancia general de cada variable en el modelo) como locales (explicación de una predicción específica para un paciente particular).

Funcionamiento técnico: Los valores SHAP se calculan considerando todas las posibles combinaciones de características (coaliciones). Para una variable i y una predicción dada, el valor SHAP se define como la diferencia entre la predicción

esperada con dicha variable presente y la predicción esperada con la variable ausente, promediada sobre todas las permutaciones posibles. Formalmente, el valor de Shapley para la variable i es:

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} [f(S \cup \{i\}) - f(S)]$$

donde F es el conjunto de todas las características, S es un subconjunto de características, y $f(S)$ es la predicción del modelo con el subconjunto S .

Interpretación de resultados: En el contexto del shock hemorrágico, los valores SHAP se interpretan de la siguiente manera: un valor SHAP positivo para una variable indica que esta incrementa la probabilidad predicha de shock; un valor negativo indica que reduce dicha probabilidad. Por ejemplo, si un paciente tiene un valor SHAP alto para `HB_PREQX`, significa que su hemoglobina preoperatoria contribuyó significativamente a que el modelo predijera un riesgo elevado. En la práctica, esto permite al médico identificar rápidamente los factores de riesgo más relevantes para ese paciente específico, facilitando la discusión clínica y la toma de decisiones sobre intervenciones preventivas.

- **Local Interpretable Model-agnostic Explanations (LIME):** complementa a SHAP al aproximar localmente el comportamiento de un modelo complejo mediante un modelo interpretable (como una regresión lineal) en torno a una predicción individual. Esto permite generar explicaciones intuitivas por ejemplo, destacando las tres variables más influyentes en una alerta de alto riesgo, aunque con menor rigor teórico que SHAP. Ambas técnicas son compatibles con cualquier modelo (model-agnostic) y son ampliamente utilizadas en aplicaciones médicas para garantizar que las decisiones automatizadas sean auditables y clínicamente razonables.

2.4. Estándares de reporte: TRIPOD

Para validar que un modelo sea clínicamente útil debe seguir estándares de desarrollo. La declaración Transparent Reporting of a multivariable Prediction model for Individual Prognosis or Diagnosis (TRIPOD) [6] está diseñada para garantizar transparencia, calidad y reproductibilidad, lo cual es esencial para evaluar la generalización del modelo en distintas poblaciones y sistemas de salud.

3. Estado del Arte

En los últimos años, el campo de la inteligencia artificial aplicada a la predicción de complicaciones postoperatorias ha experimentado un crecimiento significativo, siguen siendo pocos los estudios que destacan por sus resultados o procedimientos en la prevención del shock hemorrágico. Los modelos de ML surgen entonces como herramientas prometedoras para superar las limitaciones de los métodos tradicionales al integrar múltiples variables clínicas y proporcionar predicciones más precisas. Sin embargo, aún quedan desafíos metodológicos y prácticos que limitan su implementación clínica.

3.1. Modelo predictivo para hemorragia pospancreatectomía

Zhang et al. [7] desarrollaron y validaron externamente un modelo de machine learning para la estratificación precisa del riesgo de hemorragia pospancreatectomía (PPH) mediante una cohorte internacional. El estudio utilizó una cohorte de entrenamiento de 3,609 pacientes de la base de datos del American College of Surgeons National Surgical Quality Improvement Program (ACS-NSQIP) y una cohorte de validación externa de 1,347 pacientes del National Cancer Center en China. Los investigadores compararon múltiples algoritmos evaluados, incluyendo GBM, Deep Neural Networks (DNN) y Logistic Regression, seleccionando finalmente el Lasso-GBM, el cual identificó predictores claves como: el índice de masa corporal (IMC), la clasificación ASA, la administración de esteroides preoperatorios, el uso de betabloqueadores, el tiempo quirúrgico y los niveles de hematocrito. Este enfoque usa regresión LASSO (Least Absolute Shrinkage and Selection Operator). Esta técnica es un modelo de IA que iterativamente penaliza las variables no esenciales, resuelve problemas de multicolinealidad y previene el overfitting. Sin embargo, presentó limitaciones importantes por la falta de datos temporales como el momento en el que comenzó la hemorragia y la dependencia de protocolos de centros de alta volumetría limitó su aplicabilidad en entornos menos estandarizados.

3.2. Modelo predictivo para accidente cerebrovascular perioperatorio

Cong et al. [8] desarrollaron y validaron un modelo basado en machine learning para predecir el riesgo de accidente cerebrovascular (stroke) perioperatorio en pacientes sometidos a cirugías no cardíacas, no vasculares y no neuroquirúrgicas. Utilizaron datos de 2,986 pacientes del Hospital Provincial de Henan, comparando nueve algoritmos diferentes de machine learning. El estudio desembocó en el uso de los modelos de LightGBM y KNN mostraron el mejor desempeño, con AUCs de 0.941 y 0.988 respectivamente en el conjunto de entrenamiento. Este estudio destacó por su manejo del desbalance de clases (solo el 16-20 % de los pacientes experimentaron stroke), utilizando métricas clíni-

cas relevantes como sensibilidad y F1 Score. Además, incorporó SHAP para explicar las predicciones del modelo, facilitando la interpretación clínica. Sin embargo, el estudio y su enfoque en predicción preoperatoria no abordó la detección temprana postoperatoria que sería necesaria para intervenciones inmediatas.

3.3. Predicción del recuperación de shock hemorrágico severo usando regresión logística

Aunque la mayoría de los avances recientes en predicción de shock hemorrágico se han centrado en modelos clínicos con machine learning, algunos estudios preclínicos han explorado enfoques similares en modelos animales. En este caso, Lucas et al. [9] desarrollaron un modelo de regresión logística con selección rigurosa de características que logró predecir la recuperación tras shock hemorrágico severo en ratas con una precisión del 84 %, superando a los métodos tradicionales basados únicamente en presión arterial y frecuencia cardíaca. Este enfoque metodológico, aunque no directamente aplicable en entornos clínicos humanos, refuerza el potencial de los modelos predictivos basados en múltiples parámetros fisiológicos para mejorar la toma de decisiones en situaciones críticas, lo que respalda la viabilidad de desarrollar sistemas similares adaptados al entorno postoperatorio humano.

3.4. Modelos multimodales para pronóstico en UCI

Pal et al. [16] presentaron ShockModes, un modelo multimodal para la predicción de resultados en UCI que integra tres fuentes de datos heterogéneas: notas clínicas de médicos procesadas con DocBERT (un Transformer entrenado en textos médicos), series temporales de signos vitales (frecuencia cardíaca, presión arterial, SpO₂) procesadas con Regresión Logística, Random Forest, GradientBoost, AdaBoost y XGBoost, y datos de comorbilidades del paciente. El modelo alcanzó un recall de 0.81 y una especificidad de 0.94, demostrando el potencial de las arquitecturas multimodales en este dominio. Sin embargo, los propios autores reconocen que este enfoque requiere volúmenes de datos significativamente mayores y una infraestructura de recolección de datos más compleja que la disponible en la mayoría de centros clínicos. En nuestro caso, contamos únicamente con una de estas fuentes de datos (variables tabulares), lo que contextualiza las limitaciones de nuestro modelo en comparación con este referente.

3.5. Limitaciones de los modelos predictivos clínicos

Ma et al. [15] realizaron una revisión sistemática sobre el manejo deficiente de predictores continuos en modelos de predicción clínica. Su análisis reveló que la dicotomización de variables continuas (como convertir la edad o la hemoglobina en categorías

binarias) y el uso de categorías arbitrarias para predictores continuos son prácticas extendidas que reducen significativamente la precisión predictiva de los modelos, al disminuir la información disponible sobre la verdadera distribución de cada variable. Esto es relevante para nuestro trabajo: los experimentos de categorización de EDAD y HB_PREQX no produjeron mejoras y, de acuerdo con estos hallazgos, pudieron haber introducido pérdida de información.

Complementariamente, Steyerberg et al. [17] analizaron las principales problemáticas de los enfoques de modelado tradicionales en contextos clínicos, identificando como riesgos críticos: el uso de datasets de tamaño reducido esperando generalización amplia, la categorización de predictores continuos, y la sobreestimación de los resultados del análisis estadístico (modelos que presentan resultados muy favorables en la evaluación interna pero que rinden significativamente peor en aplicación clínica real). Este último punto es especialmente pertinente en nuestro estudio, donde la optimización del umbral de decisión permitió mejorar el rendimiento en el conjunto de prueba a pesar de que los valores de la validación cruzada fueron moderados.

3.6. Síntesis y brecha de conocimiento

La revisión de estos estudios revela importantes avances metodológicos en la aplicación de machine learning para predecir complicaciones postoperatorias, pero también identifica una brecha crítica que aborda este proyecto: la ausencia de un sistema especializado para la detección temprana del shock hemorrágico postoperatorio en cirugía mayor no cardíaca. Mientras Zhang et al. [7] desarrollaron un modelo predictivo para hemorragia pospancreatectomía y Cong et al. [8] se enfocaron en la predicción de stroke perioperatorio, ninguno aborda específicamente la detección temprana del shock hemorrágico en el período postoperatorio, cuando los signos clínicos pueden ser sutiles pero la intervención oportuna es crítica para la supervivencia. El estudio ShockModes [16] demuestra el potencial de las arquitecturas multimodales, pero requiere fuentes de datos heterogéneas que superan los datos disponibles en este proyecto. La brecha que aborda este proyecto es, por tanto, muy específica: desarrollar un sistema de alerta temprana basado en inteligencia artificial que permita identificar pacientes en riesgo de shock hemorrágico durante el período postoperatorio, reconociendo las limitaciones metodológicas señaladas por Ma et al. [15] y Steyerberg et al. [17].

Tabla 2: Estado del arte en modelos predictivos para complicaciones postoperatorias

Proyecto	Temática principal	Metodología	Limitaciones
Zhang et al. [7]	Modelo predictivo para hemorragia pospancreatectomía	Modelo Lasso-GBM validado externamente; enfoque en explicabilidad clínica	Diseño retrospectivo restringió acceso a variables quirúrgicas detalladas; dependencia de protocolos de centros de alta volumetría
Cong et al. [8]	Modelo predictivo para stroke peroperatorio	LightGBM y KNN mostraron mejor desempeño (AUC 0.941 y 0.988); utilizó SHAP para explicabilidad clínica	Diseño retrospectivo con acceso limitado a variables quirúrgicas granulares; enfoque en predicción preoperatoria, no en detección temprana postoperatoria; no específico para shock hemorrágico
Lucas et al. [9]	Predicción de recuperación tras shock hemorrágico severo mediante regresión logística	Regresión logística con selección rigurosa de características; evaluación de tres clasificadores: con todas las características, con conjunto reducido y solo MAP y HR	Precisión del 84 % en predicción de recuperación; modelo aplicado en contexto preclínico (ratas); no generalizable directamente a entornos clínicos humanos
Pal et al. [16]	Modelo multimodal para pronóstico en UCI (Shock-Modes)	Integración de notas clínicas (DocBERT), series temporales de signos vitales y comorbilidades; recall 0.81, especificidad 0.94	Requiere múltiples fuentes de datos heterogéneas; infraestructura de recolección compleja; necesita volúmenes de datos mayores según los autores
Ma et al. [15]; Steyerberg et al. [17]	Limitaciones metodológicas en modelos predictivos clínicos	Revisión sistemática de prácticas de modelado en regresión logística y validación interna	Categorizar predictores continuos reduce la precisión predictiva; datasets pequeños no garantizan generalización; sobreestimación de resultados estadísticos respecto al rendimiento clínico real

4. Metodología

El desarrollo del proyecto se basa en la integración de dos marcos metodológicos complementarios: CRISP-DM (Cross Industry Standard Process for Data Mining) [10], ampliamente reconocido en el ámbito del análisis de datos e inteligencia artificial, y la guía TRIPOD (Transparent Reporting of a multivariable Prediction model for Individual Prognosis or Diagnosis) [6], orientada a garantizar transparencia, reproducibilidad y rigor metodológico en el desarrollo de modelos predictivos clínicos.

El uso conjunto de ambos enfoques permite estructurar el proyecto desde una perspectiva técnico-científica, asegurando no solo la calidad del modelo, sino también su validez clínica y su potencial de integración en entornos hospitalarios.

4.1. Fases metodológicas

Fase 1: Comprensión del problema y objetivos clínicos

Corresponde a la formulación inicial del problema, el análisis del contexto clínico y la definición de los objetivos específicos del modelo predictivo. Durante esta fase se identifican los interesados principales (anestesiólogos, investigadores clínicos y especialistas en IA), los criterios de éxito clínico, así como las restricciones éticas y técnicas asociadas al manejo de datos sensibles. Esta fase se desarrolla siguiendo la primera etapa de CRISP-DM Business Understanding y las directrices iniciales de TRIPOD relativas a la definición clara del objetivo de predicción y la población de estudio. Se utiliza Microsoft Word para la documentación formal, Sharepoint para control colaborativo de versiones y Mendeley para la gestión de referencias.

Fase 2: Comprensión y preparación de los datos

En esta etapa se realiza el análisis exploratorio y la preparación del conjunto de datos proporcionado por la Fundación Valle del Lili (FVL), siguiendo las etapas Data Understanding y Data Preparation de CRISP-DM.

Las actividades incluyeron:

- Exploración de distribución de variables clínicas y manejo de valores atípicos.
- Limpieza, transformación y codificación de variables categóricas y numéricas.
- Análisis de correlaciones y selección de variables relevantes con base en criterios clínicos y estadísticos.

De acuerdo con TRIPOD, en esta fase también se documentaron las características de la población, los métodos de adquisición de datos, los criterios de exclusión y el tratamiento de valores faltantes, garantizando la trazabilidad de los procedimientos.

Las herramientas utilizadas son: Python (con librerías Pandas, NumPy, Matplotlib, Seaborn, entre otras) y Jupyter Notebook para el análisis exploratorio y la limpieza de datos; GitHub para control de versiones.

Es importante señalar que el tamaño muestral disponible constituye una limitación inherente a esta fase. Aunque el dataset de la FVL representa información valiosa del contexto quirúrgico local, la cantidad de registros limita la capacidad de generalización del modelo y el techo de desempeño discriminativo alcanzable. Como señalan Steyerberg et al. [17], los resultados de evaluación interna no garantizan transferencia directa al entorno clínico real; por tanto, los hallazgos de este estudio deben interpretarse en el contexto de una validación preliminar.

Fase 3: Modelado y experimentación

Esta fase corresponde a las etapas Modeling y Evaluation de CRISP-DM, y constituye el núcleo del trabajo actual. En ella se compararán distintos algoritmos de aprendizaje supervisado entre ellos Random Forest, Gradient Boosting (LightGBM) con el fin de determinar el modelo de mejor desempeño para la predicción temprana de shock hemorrágico.

Las actividades contempladas son:

- División del dataset en conjuntos de entrenamiento, validación y prueba.
- Ajuste de hiperparámetros mediante validación cruzada estratificada.
- Evaluación del desempeño con métricas clínicas: sensibilidad, especificidad, F1-score, AUC-ROC y calibración, con enfoque en alta sensibilidad.
- Interpretabilidad del modelo mediante técnicas SHAP para garantizar la transparencia y la validación clínica de los resultados.

La estrategia de validación empleada utiliza validación cruzada estratificada de k-pliegues (k-fold), técnica estándar en el desarrollo de modelos predictivos clínicos que permite aprovechar la totalidad del dataset para la evaluación mientras se mitiga el riesgo de sobreajuste. La estratificación garantiza que cada pliegue mantenga la misma proporción de casos positivos (shock) y negativos (no shock), aspecto crítico dado el desbalance inherente de la variable objetivo.

La selección de métricas de evaluación responde a criterios clínicos rigurosos. El área bajo la curva ROC (AUC-ROC) constituye la métrica primaria por su invariance al umbral de clasificación, permitiendo evaluar la capacidad discriminativa del modelo independientemente del punto operativo seleccionado. La sensibilidad (recall) mide la proporción de casos de shock correctamente identificados, métrica prioritaria en contextos donde la detección temprana tiene valor vital. La especificidad complementa esta evaluación al cuantificar la capacidad del modelo para evitar falsas alarmas, aspecto directamente relacionado con la fatiga de alertas en entornos clínicos. El F2-score pondera

la sensibilidad con mayor peso que la precisión, penalizando más los falsos negativos que los falsos positivos, lo cual se alinea con el principio de priorización de detección en medicina.

Desde la perspectiva TRIPOD, esta fase incluye la documentación exhaustiva del proceso de modelado, el método de validación interna y el análisis de robustez y sesgos. La ausencia de validación externa (datos de otras instituciones) constituye una limitación que debe considerarse al evaluar la aplicabilidad del modelo en poblaciones diferentes a la del estudio.

Fase 4: Validación clínica preliminar

En esta etapa se realiza una evaluación preliminar del modelo junto con expertos médicos, utilizando escenarios quirúrgicos históricos simulados. El propósito es verificar la coherencia clínica de las predicciones y la aplicabilidad práctica del modelo en entornos reales.

Esta fase sigue las recomendaciones TRIPOD sobre validación y reporte de resultados, incluyendo:

- Identificación de limitaciones y posibles fuentes de sesgo.
- Elaboración de tablas y figuras explicativas conforme a los lineamientos de reporte TRIPOD.

La interpretación clínica de los resultados requiere considerar el contexto específico del estudio. Un AUC-ROC de 0.64 representa un desempeño moderado que, aunque insuficiente para implementación clínica directa, constituye una línea base valiosa para investigación exploratoria. La brecha entre el rendimiento observado y el ideal ($AUC = 1.0$) refleja limitaciones inherentes al diseño del estudio: datos tabulares estáticos (sin variables temporales), definición simplificada de la variable objetivo (binaria en lugar de estratificada por severidad), y dependencia de información pre e intraoperatoria sin acceso a señales dinámicas en tiempo real.

Fase 5: Despliegue y Documentación final

Se consolida la documentación técnica y científica del proyecto, incluyendo el informe final, las visualizaciones de resultados y los anexos de código reproducible. En este caso, no se integrará el modelo con los sistemas de FVL, pero se busca realizar la etapa Deployment de CRISP-DM con versionamiento de modelos. La arquitectura de software desarrollada, basada en un pipeline parametrizado con orquestación mediante Apache Airflow, constituye el fundamento tecnológico para una futura integración con sistemas hospitalarios. Esta arquitectura permite que el modelo sea actualizado y reentrenado de forma sistemática conforme se disponga de nuevos datos, facilitando la transición de la fase experimental a la implementación real.

4.2. Recopilación de limitaciones del estudio

A manera de síntesis y siguiendo las directrices de reporte TRIPOD, se consolidan las limitaciones identificadas a lo largo del documento:

1. **Definición de la variable objetivo:** La variable objetivo (shock hemorrágico) fue definida como variable booleana binaria en lugar de utilizar criterios clínicos precisos que distingan entre clases de shock (compensado, descompensado, irreversible). Esta simplificación limita la capacidad del modelo para capturar la severidad y el estadio evolutivo del shock hemorrágico.
2. **Tamaño y cobertura del dataset:** El tamaño muestral y la naturaleza de los datos limitan la capacidad de generalización y el techo de desempeño discriminativo. Como señalan Steyerberg et al. [17], los resultados de evaluación interna no garantizan transferencia directa al entorno clínico real.
3. **Desbalance de clases y técnicas de balanceo:** La proporción 2.1:1 entre casos negativos y positivos requirió técnicas de balanceo (SMOTE, class weights). El sobremuestreo sintético en datasets pequeños puede crear patrones artificiales, lo cual explica parcialmente los altos valores de recall con baja especificidad observados en algunos experimentos.
4. **Manejo de variables continuas:** Los experimentos de categorización de EDAD y HB_PREQX no produjeron mejoras en el rendimiento. Este resultado está en línea con la revisión sistemática de Ma et al. [15], que demuestra que la dicotomización y categorización de predictores continuos conlleva pérdida de información y reduce la precisión de los modelos de predicción clínica.
5. **Fuentes de datos unimodales:** A diferencia de enfoques como ShockModes [16], que combina notas clínicas, series temporales de signos vitales y comorbilidades, este proyecto cuenta únicamente con variables tabulares estáticas. La ausencia de variables dinámicas limita la capacidad predictiva del modelo, ya que el shock hemorrágico es un proceso evolutivo que no se captura completamente con datos estáticos.
6. **Validación externa:** El modelo no fue validado en poblaciones externas a la Fundación Valle del Lili, lo que limita la generalización de los resultados a otras instituciones o poblaciones.
7. **Fatiga de alertas:** En el modelo final `random_forest`, la especificidad de 0.3567 en el umbral operativo implica una tasa considerable de falsas alarmas. En entorno real, esto puede deteriorar la adherencia del personal a las alertas.

5. Desarrollo de la propuesta

5.1. Comprensión y preparación de los datos

En nuestro caso, el análisis comenzó una vez se nos fueron entregados los datos desde la Fundación Valle del Lili (FVL). Se nos dio un archivo del tipo “Comma Separated Value” (CSV) al que nos referiremos como “dataset” desde ahora. Nuestro análisis inicial se orientó principalmente a los objetivos específicos a y b. Con una descripción inicial del dataset encontramos como característica principal que no contiene nulos ni duplicados, razón por la que no se documenta limpieza alguna.

Tabla 3: Métricas iniciales del dataset

Métrica	Valor
Número de filas	1324
Número de columnas	22
Duplicados	0
Valores nulos totales	0
Ratio de desbalance	0.4760

A la par que recibimos los datos. Se nos fue entregado un diccionario de definiciones que describían la naturaleza de los datos (a excepción de su método de recolección). El diccionario contenía la siguiente información.

Tabla 4: Diccionario de variables del dataset

Nombre de la variable	Definición	Tipo de variable
EDAD	Edad del paciente	Cuantitativa continua (Entero)
GENERO	Género del paciente	Cuantitativa nominal (0:femenino, 1:masculino)
ACT_FISICA_METS	Paciente con actividad física	Cualitativa nominal (0: Inactiva, 1: Activa)
HB_PREQX	Nivel de hemoglobina prequirúrgica	Cualitativa continua (Decimal), rango: 0.0 - 25.0 g/dL
HIPERTENSION	Alta presión en la sangre	Cualitativa nominal (0: Inactiva, 1: Activa)
DIABETES	Presencia de diabetes	Cualitativa nominal (0: Inactiva, 1: Activa)

Nombre de la variable	Definición	Tipo de variable
ENFERMEDAD_CORONARIA	Presencia de enfermedad coronaria	Cualitativa nominal (0: Inactiva, 1: Activa)
FALLA_CARDIACA	Presencia de falla cardiaca	Cualitativa nominal (0: Inactiva, 1: Activa)
HIPOTIROIDISMO	Presencia de hipotiroidismo	Cualitativa nominal (0: Inactiva, 1: Activa)
ERC	Presencia de enfermedad renal crónica	Cualitativa nominal (0: Inactiva, 1: Activa)
INMUNOSUPRESION	Presencia de inmunosupresión	Cualitativa nominal (0: Inactiva, 1: Activa)
OBESIDAD	Presencia de obesidad	Cualitativa nominal (0: Inactiva, 1: Activa)
HIPERTENSION_PULMONAR	Presencia de alta presión sanguínea en los pulmones	Cualitativa nominal (0: Inactiva, 1: Activa)
EPOC	Presencia de enfermedad pulmonar obstructiva crónica (COPD)	Cualitativa nominal (0: Inactiva, 1: Activa)
ASMA	Presencia de asma	Cualitativa nominal (0: Inactiva, 1: Activa)
ENF_CEREBROVASCULAR	Presencia de enfermedad cerebrovascular	Cualitativa nominal (0: Inactiva, 1: Activa)
CANCER_ACTIVADO	Presencia de cualquier tipo de cáncer activo	Cualitativa nominal (0: Inactiva, 1: Activa)
TABAQUISMO	Tabaquismo	Cualitativa nominal (0: Inactiva, 1: Activa)
SANGRADO_MAYOR	Si tuvo una pérdida excesiva de sangre en el momento de la cirugía	Cualitativa nominal (0: Inactiva, 1: Activa)
SHOCK	Presencia de shock hemorrágico hipovolémico después de la cirugía	Cualitativa nominal (0: Inactiva, 1: Activa)
MUERTE.1	Muerte luego de la primera semana de cirugía	Cualitativa nominal (0: Inactiva, 1: Activa)

Cada una de estas características estaban segmentadas por distintas categorías elegidas desde FVL.

Características sociodemográficas: EDAD, GENERO

Características preoperatorias: ACT_FISICA_METS, HB_PREQX

Características en operación: SANGRADO_MAYOR

Comorbilidades: HIPERTENSION, DIABETES, ENFERMEDAD_CORONARIA, FALLA_CARDIACA, HIPOTIROIDISMO, ERC, INMUNOSUPRESION, OBESIDAD, HIPERTENSION_PULMONAR, EPOC, ASMA, ENF_CEREBROVASCULAR, CANCER_ACTIVADO, TABAQUISMO

Características postoperatorias: SHOCK

Resultados postoperatorios: MUERTE.1

5.1.1. Variable objetivo

Dado que shock es nuestra variable objetivo (VO), procedimos a analizar la distribución de las variables clínicas, comenzando por la VO. En la figura se observa un desbalance notable, con un 67.9 % de casos sin shock (0) y un 32.1 % de casos con shock (1). Esto indica una desproporción significativa entre ambas clases, el nivel de desbalanceo es de 2.1:1 calculándolo como siendo mucho más frecuentes los casos en los que no se presentó shock.




Figura 1: Variable objetivo - Shock

5.1.2. Variables continuas

Proseguimos con el análisis de Edad y HB_PREQX. Lo que vemos son las distribuciones agrupadas por VO, donde las barras de color rosa corresponden a los casos de shock y las barras de color café corresponden a los casos en los que no hubo shock. Vemos una distribución muy similar a una campana de Gauss para ambas variables, donde la mayoría de los casos se centran en las personas de 60 años para la variable de Edad. De igual forma, la variable HB_PREQX tiene su mayor peso entre los niveles 13 y 14. La forma en la que se medirá la relevancia contra la VO para las variables numéricas será con el estadístico de Cohen's d [11]. Esta es una medida de tamaño del efecto que se utiliza para cuantificar la magnitud de la diferencia entre las medias de dos grupos, expresada en unidades de desviación estándar. Para ejecutarlo correctamente sobre la VO que es binaria, tomaríamos entonces la media de los casos en los que hubo shock y lo restamos con la media de las veces en las que no hubo, esto lo dividimos entre la desviación estándar agrupada para las medias de ambos grupos, formulando lo siguiente:

$$d = \frac{\bar{X}_{shock} - \bar{X}_{no\ shock}}{S_{pooled}}$$

A partir del coeficiente, se ha introducido una serie de rangos de interpretación formulados por el mismo autor del estadístico, los cuales son:

Tabla 5: Interpretación del coeficiente de Cohen's d

Cota inferior (no inclusiva)	Cota superior (inclusiva)	Interpretación
0	0.05	Efecto muy pequeño
0.05	0.15	Efecto pequeño
0.15	0.25	Efecto mediano
0.25	+1	Efecto grande

Sin embargo, que el coeficiente de Cohens nos diga que es relevante no es suficiente si los datos que tenemos nos indican que realmente no hay suficientes datos para confirmar que es confiable. Para corregir esto usamos el valor P.

El valor P es otro estadístico que nos permite comprobar la hipótesis nula sobre un conjunto de datos [12]. Formalmente se describe como:

Siendo nuestro caso, el que es “No existe diferencia en las medias poblacionales de la variable numérica entre los dos grupos definidos por la VO.”, cada una de estas hipótesis siendo evaluada a un nivel de confianza de 0.05 para la aceptación de la nula. Así obteniendo tanto relevancia con la VO como confianza sobre la característica.

Con respecto a la descripción estadística de las variables numéricas, encontramos los siguientes datos:

Edad:

- Promedio sin shock: 53.71 años
- Promedio con shock: 59.57 años
- Desviación estándar sin shock: 20.46 años
- Desviación estándar con shock: 18.79 años
- Mínimo: 1 año
- Máximo: 95 años
- Cohens-d: 0.294. Medianamente relevante.
- P_value: 3.94E-07. Confiable.

HB_PREQX:

- Promedio: 12.926 g/dL
- Desviación estándar: 2.023 g/dL
- Mínimo: 5 g/dL
- Máximo: 19.0 g/dL
- Cohens-d: -0.0670. Nada relevante por sí mismo.
- P_value: 0.262. Se rechaza la nula y se acepta que la cantidad de datos de la hemoglobina prequirúrgica por sí sola no es una característica que sea relevante para el entrenamiento.




Figura 2: Interpretación de Cohen's d

5.1.3. Variables booleanas

La composición del resto del dataset eran datos categóricos booleanos, de estos solo se obtuvo su frecuencia y su relación con la VO. En el proceso describimos cada una de forma general, luego mostraremos nuestro procedimiento para descartar su influencia sobre la VO.

GENERO: Esta variable indica que hay una desproporción en los datos de hombres y mujeres en dataset, ya que vemos que los hombres (1) representan aproximadamente el 32 % del dataset, mientras que las mujeres ocupan aproximadamente el 68 % de este. Concluimos también que el shock afecta de igual forma tanto a hombres en la misma proporción.




Figura 3: GENERO: Distribución por género

ACT_FISICA_METS: Se muestra una proporción similar al género en la actividad física, con un leve decremento cuando hay presencia de shock. Concluimos que el shock afecta en la misma medida a las personas que hacen deporte como a las que no.




Figura 4: ACT_FISICA_METS: Actividad física

Muerte: Esta variable es postoperatoria es inservible cuando se trata de la pre-

dicción temprana del shock hipovolémico, por lo que no ha fue tomada en cuenta para el desarrollo temprano del modelo de IA. Sin embargo, esta variable será usada en posteriores análisis para la búsqueda de los mejores selectores. Vemos de igual modo que con respecto a la VO, que no todos los que murieron estuvieron relacionados con el shock.




Figura 5: Muerte: Variable postoperatoria

HIPERTENSION: Con respecto al shock, la gráfica muestra que no hay diferencia entre las poblaciones que sufren o no hipertensión.




Figura 6: HIPERTENSION

DIABETES: En esta gráfica vemos que tampoco hay una mayor influencia sobre la VO.




Figura 7: DIABETES

ENFERMEDAD_CORONARIA: En este caso vemos una mayor influencia sobre la VO cuando se presenta esta comorbilidad, por lo que concluimos que podría ser un factor clave para el entrenamiento o las agregaciones.




Figura 8: ENFERMEDAD_CORONARIA

FALLA_CARDIACA: Esta característica fue tratada como una que se ve afectada por el entorno controlado de los hospitales. Según los expertos de FVL este comportamiento resulta de que las personas con esta complicación son altamente monitoreadas, por lo que son menos propensas a sufrir un shock hipovolémico. Concluimos que la presencia de esta comorbilidad no influye en la VO.




Figura 9: FALLA_CARDIACA

HIPOTIROIDISMO: Vemos que no tiene mayor influencia en la VO.




Figura 10: HIPOTIROIDISMO

ERC: Con esta variable podemos concluir que aquellas personas que presentan esta enfermedad son menos propensas a sufrir un shock hipovolémico, según los expertos de FVL tiene la misma explicación que con la falla cardíaca y el alto seguimiento del riesgo con las personas que presentan esta comorbilidad.




Figura 11: ERC

OBESIDAD: Vemos que la obesidad no influye de forma notoria sobre la VO.




Figura 12: OBESIDAD

HIPERTENSION_PULMONAR: En este caso, vemos que el poseer o no esta complicación afecta en gran medida el riesgo de shock.




Figura 13: HIPERTENSION_PULMONAR

EPOC: Aquí vemos que el poseer o no esta enfermedad no influye directamente en la VO.




Figura 14: EPOC

ASMA: Vemos que no tiene una mayor incidencia sobre la VO.




Figura 15: ASMA

ENF_CEREBROVASCULAR: Vemos que no tiene mayor influencia sobre la VO.




Figura 16: ENF_CEREBROVASCULAR

5.2. Discriminación inicial de la relevancia de las características sobre la VO

Para poder tener una comprensión más detallada de que comorbilidades influían realmente sobre la VO usamos la matriz de coeficientes de Cramér's V [13]. Esta es una medida de asociación entre dos variables nominales que proporciona un valor entre 0 y 1 (inclusivo), donde 0 indica ausencia de asociación y 1 indica asociación perfecta. Este coeficiente se basa en la estadística de chi-cuadrado de Pearson y fue desarrollado por el estadístico sueco Harald Cramér.

La matriz de coeficientes de Cramér's V extiende este concepto calculando el coeficiente de Cramér's V para cada par de variables categóricas en un dataset, creando así una lista de correlación específica para variables categóricas, concepto ideal para el análisis de las comorbilidades booleanas. Al hacer la aplicación sobre el dataset se obtuvo la siguiente figura.




Figura 17: Matriz de Cramér's V

5.3. Estrategia experimental

La etapa experimental se estructuro en cinco experimentos secuenciales: *baseline*, *agregaciones*, *categorizaciones*, *pruning* e *hiperparametros*. Esta nomenclatura coincide con el flujo de experimentacion definido para la sustentacion.

Todas las metricas reportadas en esta seccion se obtienen directamente de los metadatos generados por el pipeline, usando como fuente primaria:


- `doc/experiments/tmp_metrics_summary.tsv` para metricas consolidadas por experimento y modelo.
- `doc/experiments/exp_05_hyperparameter_search/models/<modelo>/plots/plot_metadata.` para métricas operativas detalladas de la comparación final de modelos.

5.4. Experimento 1: Baseline


En el experimento baseline se evaluaron siete algoritmos con configuracion base para establecer la linea de referencia.

Tabla 6: Top 3 modelos por AUC-ROC en el Experimento 1

Modelo	AUC-ROC
catboost	0.6153
logistic_regression_lasso	0.6055
xgboost	0.5950



(a) Comparacion ROC global



(b) Importancia variables (catboost)

Figura 18: Resultados Experimento 1

5.5. Experimento 2: Agregaciones

Se incorporaron variables derivadas y agregaciones clinicas para aumentar la capacidad discriminativa del modelo. El mejor resultado de esta fase fue catboost con AUC-ROC de 0.6192.

Tabla 7: Top 3 modelos por AUC-ROC en el Experimento 2

Modelo	AUC-ROC
catboost	0.6192
logistic_regression_lasso	0.6055
xgboost	0.6045




Figura 19: Resultados Experimento 2

5.6. Experimento 3: Categorizaciones

Se evaluo la categorizacion de variables continuas en rangos clinicos. El resultado mostro una caida frente al experimento anterior, con mejor AUC-ROC de 0.6134 (catboost), lo cual sugiere perdida de informacion discriminativa al discretizar.

Tabla 8: Top 3 modelos por AUC-ROC en el Experimento 3

Modelo	AUC-ROC
catboost	0.6134
logistic_regression_lasso	0.6037
xgboost	0.5950




Figura 20: Comparacion ROC global del Experimento 3

5.7. Experimento 4: Pruning

La cuarta fase se enfoco en reducir ruido y mantener solo características con mayor utilidad predictiva. Se descartaron siete variables de baja ocurrencia (criterio minimo: 10 casos) que mostraron aporte marginal al desempeño discriminativo en fases previas.


Tabla 9: Variables descartadas en feature pruning

Variable
ENFERMEDAD_CORONARIA
FALLA_CARDIACA
INMUNOSUPRESION
HIPERTENSION_PULMONAR
EPOC
ASMA
ENF_CEREBROVASCULAR


Tras la eliminacion de estas variables, catboost volvio a liderar con AUC-ROC de 0.6237, manteniendo resultados competitivos con un conjunto de caracteristicas mas compacto.

Tabla 10: Top 4 modelos por AUC-ROC en el Experimento 4

Modelo	AUC-ROC
catboost	0.6237
logistic_regression_lasso	0.6067
xgboost	0.6038
lightgbm	0.5995



(a) Comparacion ROC global




(b) ROC CV catboost (lider)


Figura 21: Resultados Experimento 4

5.7.1. Comparativa complementaria en pruning

Para reproducir el analisis de la presentacion, se incorpora la comparativa visual de curvas ROC en CV para los contendientes `logistic_regression_lasso` y `xgboost` bajo el mismo esquema de poda.



(a) Logistic Regression Lasso



(b) XGBoost


Figura 22: Curvas ROC en CV - Comparativa complementaria Experimento 4

5.8. Experimento 5: Hiperparametros


La fase final realizo optimizacion de hiperparametros para todos los modelos y consolido la comparacion final de desempeno.

Tabla 11: Ranking de modelos por AUC-ROC en el Experimento 5

Ranking	Modelo	AUC-ROC
1	random_forest	0.6404
2	lightgbm	0.6384
3	xgboost	0.6371
4	decision_tree	0.6354
5	catboost	0.6215
6	logistic_regression_lasso	0.6068
7	naive_bayes	0.5707



(a) Comparacion ROC global



(b) Distribucion AUC-ROC CV

Figura 23: Desempeno comparativo Experimento 5




Figura 24: Importancia de variables del modelo lider (random_forest) en el Experimento 5


5.8.1. Comparativa final: Random Forest vs Decision Tree

Para la decision final se contrasto el mejor modelo discriminativo (random_forest) frente al mejor candidato interpretable (decision_tree), usando las metricas de operacion reportadas en `plot_metadata.json`.


Tabla 12: Comparativa de métricas operativas en el Experimento 5 (Comparación Final de Modelos)

Metrica	random_forest	decision_tree
AUC-ROC (CV)	0.6404	0.6354
Threshold optimo	0.38	0.22
Recall	0.8196	0.8568
Specificity	0.3567	0.3154
Precision	0.3755	0.3713
NPV	0.8074	0.8235
F1-score	0.5150	0.5180
F2-score	0.6628	0.6791
Accuracy	0.5051	0.4889
Kappa	0.1344	0.1280

Desde el criterio clinico de deteccion temprana, random_forest se prioriza por mayor AUC-ROC y mejor balance recall-especificidad. En paralelo, decision_tree conserva valor practico por su transparencia estructural y mayor interpretabilidad para discusion con equipo medico.



(a) Random Forest (AUC=0.6404)



(b) Decision Tree (AUC=0.6354)

Figura 25: Curvas ROC en CV - Experimento 5

5.8.2. Estructura e interpretacion del arbol de decision

El modelo `decision_tree` optimizado genera un clasificador binario con profundidad maxima de 7 niveles y 27 hojas terminales. La figura 26 presenta la estructura completa del arbol.




Figura 26: Estructura completa del arbol de decision optimizado (Experimento 5)

Analisis de la estructura de decision:

- **Configuracion general:** Clasificador binario basado en criterio de Gini. La Clase 0.0 (naranja, shock ausente) representa el 67.9 % de casos en el nodo raiz. La Clase 1.0 (azul, shock presente) se concentra en ramas especificas de la derecha del arbol.
- **Variables con mayor poder discriminativo:** `SANGRADO_MAYOR` actua como variable de division en el nodo raiz (critica para identificacion temprana). `EDAD` modula la probabilidad de shock en ambas ramas principales. `HB_PREQX` y `SINDROME_METABOLICO` refinan la clasificacion en nodos internos.
- **Logica de decision principal:** La rama de `SANGRADO_MAYOR > 1,582` constituye la ruta critica para identificar casos de shock (Clase 1.0), especialmente cuando se combina con `EDAD > 0,236` (Z-score estandarizado), generando alta pureza de clase positiva. Si el sangrado es $\leq 1,582$, la probabilidad de shock es minima (< 0.20), salvo interacciones especificas entre edad y hemoglobina preoperatoria.
- **Perfil de riesgo maximo:** El riesgo mas alto de shock (Clase 1.0) se concentra en pacientes con valores altos de sangrado intraoperatorio (Z-score $> 1,582$) y edades especificas: mayores de 65 anos (Z-score $> 0,236$) o en rango medio de 50-65 anos (Z-score entre $-0,877$ y $0,236$). La combinacion de estas condiciones eleva la probabilidad de shock por encima del 60 % en hojas terminales especificas.

5.8.3. Comparativas visuales de la comparación final de modelos

Adicionalmente se incluyen las mismas comparativas visuales presentadas en sustentación para contrastar estabilidad y comportamiento operativo entre `random_forest` y `decision_tree`.




Figura 27: Boxplot de AUC-ROC por fold en CV - Experimento 5






Figura 28: Comparativa Precision-NPV - Experimento 5




(a) Random Forest




(b) Decision Tree

Figura 29: Comparativa F1-F2 - Experimento 5




(a) Random Forest



(b) Decision Tree

Figura 30: Comparativa Kappa - Experimento 5



(a) Random Forest

(b) Decision Tree

Figura 31: Matriz de confusion normalizada - Experimento 5

5.9. Evolucion global y cierre de fase experimental

Tabla 13: Evolucion del mejor AUC-ROC por experimento

Experimento	Mejor modelo	AUC-ROC
Exp 1 (Baseline)	catboost	0.6153
Exp 2 (Features agregadas)	catboost	0.6192
Exp 3 (Variables categoricas)	catboost	0.6134
Exp 4 (Feature pruning)	catboost	0.6237
Exp 5 (Hyperparameter search)	random_forest	0.6404

En terminos absolutos, la mejora del mejor modelo entre el inicio y el cierre experimental fue:

$$\Delta AUC = 0,6404 - 0,6153 = 0,0251$$

Adicionalmente, el modelo interpretable `decision_tree` paso de AUC=0.5557 en Exp 1 a AUC=0.6354 en Exp 5, con una mejora absoluta de 0.0797.

6. Construcción de un Pipeline Parametrizado

El desarrollo de un sistema de predicción clínica basado en aprendizaje automático requiere una infraestructura de software que facilite la experimentación, garantice la reproducibilidad y permita la escalabilidad del proceso investigativo. En esta sección se expone el diseño de la arquitectura implementada para soportar los experimentos descritos previamente de una manera organizada.

El enfoque de este proyecto se fundamenta en la premisa de que la construcción de un sistema predictivo robusto requiere un estudio exploratorio sistemático. Antes de automatizar un flujo de producción, es necesario experimentar con múltiples configuraciones, algoritmos y combinaciones de características para identificar qué funciona mejor en el dominio específico de la predicción de shock hemorrágico. Por esta razón, el proyecto se diseñó como una propuesta hacia la automatización: un pipeline parametrizado que permite al investigador definir experimentos de forma declarativa, ejecutar múltiples configuraciones sin modificar código, y comparar resultados de manera sistemática.

Este enfoque de parametrización es particularmente relevante en el contexto clínico, donde las decisiones de modelado deben ser trazables, reproducibles y auditables. La metodología de experimentación sistemática (cinco experimentos secuenciales: baseline, agregaciones, categorizaciones, pruning e hiperparámetros) valida la necesidad de este diseño modular y configurable.

6.1. Evaluación de plataformas de procesamiento

Para llevar a cabo el procesamiento de los datos clínicos y la transformación de características, se consideró inicialmente el uso de tecnologías de Big Data como Apache Spark. Sin embargo, al analizar el volumen real de la información tabular disponible, se evidenció que su magnitud permitía un manejo eficiente directamente en la memoria del sistema. Incorporar una plataforma de procesamiento distribuido habría sumando una complejidad técnica en su configuración y mantenimiento que no estaba justificada para las necesidades del proyecto. Por esta razón, se prefirió un enfoque apoyado en librerías estándar de Python. Esta decisión facilitó el desarrollo y permitió mantener el flujo de trabajo funcional sin requerir infraestructura computacional adicional.

6.2. Control de la escalabilidad en la experimentación

Al adoptar un entorno basado en rutinas de Python, apareció la necesidad de organizar adecuadamente la fase de experimentación. Durante el modelado es frecuente que, al probar la inclusión de nuevas variables o ajustar parámetros, se acumulen fragmentos de código repetidos o se incluyan valores estáticos directamente en los archivos

principales.

En este trabajo, la escalabilidad técnica se entiende como la capacidad de ampliar los experimentos —añadiendo nuevos algoritmos o ajustando los existentes— sin alterar el código base. Abordar este problema fue fundamental para prevenir errores accidentales y proteger la estabilidad lógica de los flujos que ya habían sido verificados. El diseño del pipeline parametrizado responde directamente a esta necesidad: cada experimento puede ejecutarse con una configuración diferente sin necesidad de modificar los scripts de entrenamiento o evaluación.

6.3. Orquestación y reproducibilidad mediante Apache Airflow

Con la intención de dar estructura al flujo de ejecución y evitar el lanzamiento manual de tareas, se integró Apache Airflow como orquestador. Las rutinas de limpieza de datos, extracción de características, entrenamiento y evaluación fueron modeladas a través de Grafos Acíclicos Dirigidos (DAGs). Al delegar el control del proceso a un orquestador, se automatiza la resolución de dependencias entre cada paso del proceso. Esto consolida un sistema más tolerante a errores interrupciones y garantiza que la ejecución de los experimentos reportados en este documento sea replicable de manera exacta e independiente.

6.4. Desacoplamiento mediante el patrón Factory y archivos YAML

Una vez establecido el orden de ejecución con Airflow, resultó necesario separar la programación de la definición de los modelos predictivos. Para ello, se implementó el patrón de diseño *Factory*, el cual trabaja en conjunto con un administrador de configuraciones centralizado (`ConfigurationManager` en `src/utils/config_manager.py`) que consume archivos en formato YAML (`pipeline_config.yaml`).

A nivel estructural, la configuración de un modelo se consolida mediante secciones jerárquicas y autodescriptivas. En el archivo YAML se define un bloque específico para cada estimador, indicando la ruta de la librería base (el módulo fuente), el nombre exacto de la clase del algoritmo y un diccionario con los hiperparámetros que regirán su entrenamiento. Un ejemplo simplificado de esta estructura es el siguiente:

```
models:
  random_forest:
    module: "sklearn.ensemble"
    class: "RandomForestClassifier"
    params:
      n_estimators: 100
```

```
max_depth: 10
random_state: 42
```

Esta aproximación permite que los detalles de cada experimento se definan de forma completamente declarativa. Por ejemplo, al procesar el fragmento YAML anterior, el componente *Factory* centralizado en el archivo `src/models/train.py` (a través de su función `get_model_from_config`) lee las propiedades `module` y `class` del archivo de texto. Posteriormente, utilizando la librería nativa `importlib.import_module()`, el sistema instancia el estimador de manera automatizada y le transfiere sus parámetros correspondientes. A continuación, el sistema construye el *pipeline* definitivo (`create_pipeline()`) añadiendo los preprocesamientos requeridos, como la estandarización de los datos numéricos o la poda de características. Gracias a esto, cambiar de un clasificador Random Forest a un XGBoost, o alterar la profundidad máxima de un árbol, se resuelve editando unas cuantas líneas en un archivo de texto, sin necesidad de intervenir la base del método `train_model()`. Esto aísla la complejidad técnica y permite la organización de múltiples pruebas experimentales de forma limpia, sistemática y auditable.

6.5. Organización de reportes y resultados

La facilidad para plantear nuevas pruebas incremento paralelamente la generación de resultados analíticos, abarcando gráficas de desempeño (curvas ROC), métricas numéricas y resúmenes de importancia de variables.

Para asegurar un manejo ordenado de estos documentos y evitar que la información de distintos experimentos se entrelace, la arquitectura incorpora un módulo encargado de clasificar automáticamente los archivos resultantes. Terminada cada ejecución, el sistema organiza las gráficas y reportes en carpetas estructuradas según el identificador del experimento y el algoritmo evaluado. Esto facilita la consulta de la información y estandariza la recolección de resultados.

6.6. Interfaz de usuario para la validación de configuraciones

El componente final de la arquitectura consiste en una interfaz de usuario diseñada para facilitar la construcción de los archivos YAML. Dado que la redacción manual de código en texto plano hace habitual la aparición de errores en la indentación o en la escritura de los parámetros, esta herramienta gráfica valida que la configuración ingresada cumpla con el formato esperado antes de que el experimento se inicie.

La aplicación, desarrollada en Streamlit, permite al investigador configurar todos los aspectos del pipeline mediante una interfaz visual e intuitiva. A continuación se describe la estructura y funcionalidad de cada sección de la interfaz.

6.7. Descripción de la interfaz Streamlit

La interfaz del editor de configuración se estructura en diez secciones principales, accesibles desde la barra de navegación lateral. Cada sección corresponde a un componente específico del pipeline y permite su configuración de forma aislada.

La **sección de configuración general** permite al usuario definir parámetros globales del pipeline, tales como la versión del pipeline, la versión del dataset y la semilla aleatoria para reproducibilidad. También incluye opciones de visualización para las gráficas generadas (resolución DPI). Estos parámetros aseguran la trazabilidad experimental: la versión del pipeline controla las rutas de salida de modelos y resultados, mientras que la semilla aleatoria garantiza la reproducibilidad de los experimentos, aspecto fundamental en investigación científica.




Figura 32: Vista general del editor de configuración del pipeline. La interfaz permite modificar parámetros generales como versiones, semilla aleatoria y opciones de visualización.

La **sección de características** permite gestionar las variables del modelo (Figura 33). Incluye la definición de la variable objetivo (SHOCK), las características numéricas (EDAD, HB_PREQX), binarias (comorbilidades como DIABETES, HIPERTENSION), agregadas (definidas mediante operaciones aritméticas sobre otras variables) y categóricas (discretizaciones de variables continuas). Para las features agregadas y categóricas, el usuario puede habilitarlas o deshabilitarlas individualmente mediante expandibles, permitiendo un control granular sobre qué variables se incluyen en cada experimento. Los tipos de agregación disponibles son: suma, producto e inverso binario. Las features categóricas se configuran mediante umbrales sobre variables fuente.




Figura 33: Sección de configuración de características. Permite definir la variable objetivo, features numéricas, binarias, agregadas y categóricas.

La **sección de limpieza y validación de datos** permite al investigador definir reglas de calidad de datos. Incluye la especificación de columnas a excluir del dataset (como identificadores o datos de fuga), la validación de valores binarios permitidos (0 o 1) y la definición de rangos válidos para variables críticas como EDAD (mínimo y máximo) y HB_PREQX (hemoglobina prequirúrgica en g/dL). La interfaz incorpora validadores automáticos que verifican que los rangos ingresados sean coherentes, rechazando configuraciones inválidas como valores negativos de edad o valores de hemoglobina fuera del rango fisiológico plausible (0-30 g/dL).

La **sección de partición de datos (Train/Test Split)** gestiona la división del dataset para entrenamiento y evaluación. Permite configurar la proporción del conjunto de prueba (slider entre 10 % y 50 %), activar la mezcla aleatoria de datos (shuffle) y habilitar la partición estratificada para mantener la proporción de clases en train y test. La estratificación es especialmente importante en datasets desbalanceados como el del presente estudio, donde la proporción de casos de shock es menor que la de no-shock. La interfaz muestra en tiempo real la distribución resultante (ej: 80 % train, 20 % test) según la selección del usuario.

La **sección de validación cruzada** configura los parámetros de la evaluación mediante k-fold cross-validation. El investigador puede especificar el número de folds (entre 2 y 20), activar el escalamiento de features (normalización de variables numéricas, recomendada) y configurar el procesamiento paralelo (número de cores, con valor -1 para utilizar todos los disponibles). La validación cruzada estratificada garantiza que cada fold mantenga la proporción de la variable objetivo, proporcionando estimaciones más estables del rendimiento del modelo.




Figura 34: Sección de configuración de modelos. Permite habilitar/deshabilitar algoritmos, ajustar hiperparámetros y definir el recall objetivo mínimo.

La **sección de configuración de modelos** constituye el núcleo de la experimentación (Figura 34). Para cada algoritmo disponible (LightGBM, Decision Tree, Regresión Logística, Naive Bayes), el usuario puede activar o desactivar su inclusión en el experimento. Cuando un modelo está habilitado, se revela una interfaz de configuración que permite ajustar sus hiperparámetros específicos: número de estimadores, learning rate y profundidad máxima para LightGBM; profundidad máxima y mínimo de muestras para split para Decision Tree; parámetro de regularización C y tipo de penalización (L1, L2, elasticnet) para Regresión Logística. Adicionalmente, se define un umbral de recall objetivo mínimo (por defecto 0.80, no menor a 0.50) que guía la optimización del modelo en el contexto clínico. Este umbral refleja la prioridad de detectar la mayoría de casos de shock verdadero, incluso a costa de falsas alarmas.

La **sección de búsqueda de hiperparámetros** permite activar y configurar la optimización automatizada de hiperparámetros mediante técnicas como Grid Search o Random Search. Los parámetros configurables incluyen: número de iteraciones (combinaciones a probar), folds para validación cruzada durante la búsqueda y métrica de optimización (F1, F2, recall, precision, ROC-AUC). El sistema advierte al investigador que la búsqueda de hiperparámetros incrementa significativamente el tiempo de entrenamiento. La métrica F2 se destaca como prioritaria para contextos médicos, dado que penaliza más los falsos negativos que los falsos positivos.

La **sección de optimización de umbral** gestiona el punto de corte para clasificación binaria. El investigador puede definir el rango de búsqueda del umbral óptimo (valores mínimo, máximo y paso) y especificar umbrales a comparar en el conjunto de prueba. Adicionalmente, se configura el número de permutaciones para el test de significancia estadística del AUC-ROC, permitiendo evaluar si las diferencias entre modelos son estadísticamente significativas. El umbral determina a partir de qué probabilidad el

modelo clasifica un caso como shock positivo; un umbral bajo incrementa la sensibilidad pero reduce la especificidad.

La **sección de poda de características** permite eliminar features binarias con baja prevalencia en el dataset. El investigador define el número mínimo de casos positivos (unos) que una variable debe tener para ser incluida en el modelo. Esta funcionalidad automatiza la eliminación de características que, por su rareza, no aportan señal predictiva suficiente y solo introducen ruido. El threshold por defecto es 10 casos, aunque puede ajustarse según las necesidades del experimento.

La **sección de configuración de logs** gestiona el sistema de registro del pipeline. Permite seleccionar el nivel de log (DEBUG, INFO, WARNING, ERROR, CRITICAL), siendo INFO el nivel recomendado para ejecución normal. También define el directorio donde se almacenarán los archivos de log, facilitando la auditoría y el diagnóstico de errores durante la ejecución del pipeline.

El flujo de trabajo del usuario con la interfaz es el siguiente: (1) el investigador selecciona la sección deseada en la barra lateral; (2) modifica los parámetros según las necesidades del experimento; (3) guarda la configuración mediante el botón correspondiente; (4) el sistema genera automáticamente el archivo YAML con validación de formato, creando previamente un backup de la configuración anterior; (5) el pipeline puede ejecutarse con la nueva configuración, produciendo resultados organizados automáticamente en la estructura de carpetas predefinida. Adicionalmente, el usuario puede recargar la configuración desde el archivo en cualquier momento, revertiendo cambios no deseados.

Esta integración disminuye el riesgo de errores técnicos y hace el sistema más accesible, permitiendo que investigadores de sectores como la medicina puedan establecer y probar configuraciones predictivas de forma más natural e intuitiva, sin necesidad de editar archivos YAML manualmente. La interfaz actúa como una capa de abstracción que aísla la complejidad técnica del pipeline, democratizando el acceso a la experimentación algorítmica.

7. Conclusiones y futuro trabajo

7.1. Conclusiones

El desarrollo de este proyecto permitió evaluar la viabilidad de la predicción temprana del shock hemorrágico postoperatorio en pacientes sometidos a cirugía mayor no cardíaca mediante modelos de inteligencia artificial. A partir de cinco experimentos secuenciales (baseline, agregaciones, categorizaciones, pruning e hiperparámetros), se obtuvieron las siguientes conclusiones:

1. **Desempeño global moderado pero clínicamente utilizable:** El mejor desempeño global se alcanzó en el Experimento 5 con `random_forest` (AUC-ROC CV = 0.6404). Frente al baseline del Experimento 1 (AUC-ROC = 0.6153), la mejora absoluta fue de 0.0251. Este resultado, aunque modesto en términos absolutos, representa un punto de partida válido para investigación exploratoria en predicción de shock hemorrágico, considerando las limitaciones inherentes al tamaño del dataset y la naturaleza estática de las variables disponibles.
2. **Importancia de la ingeniería de variables:** Las agregaciones del Experimento 2 mejoraron el rendimiento respecto al baseline (0.6192 vs 0.6153), mientras que las categorizaciones del Experimento 3 redujeron el AUC (0.6134). Este patrón respalda la hipótesis de pérdida de información al discretizar variables continuas [15] y sugiere que las variables continuas (EDAD, HB_PREQX) deben tratarse como tales para maximizar la capacidad discriminativa.
3. **Pruning como etapa de depuración útil:** En el Experimento 4 se eliminaron siete variables de baja ocurrencia y aporte marginal, alcanzando el mejor rendimiento intermedio (0.6237), lo cual indica que la reducción de ruido favorece la capacidad discriminativa de los modelos. Esta etapa de depuración es consistente con el principio de parsimonia en modelos predictivos clínicos, donde menor complejidad frecuentemente equivale a mejor generalización.
4. **Variables con mayor señal predictiva:** En el modelo campeón (Experimento 5, `random_forest`), las variables con mayor importancia fueron EDAD (52.71 %), HB_PREQX (27.93 %) y SANGRADO_MAYOR (15.36 %). Esto sugiere que edad, hemoglobina preoperatoria y sangrado intraoperatorio constituyen los pilares de predicción para shock hemorrágico postoperatorio. La relevancia de estas variables tiene coherencia clínica: la edad avanzada implica menor reserva fisiológica, la hemoglobina baja indica menor capacidad de compensación hemorrágica, y el sangrado mayor representa la exposición directa al factor etiológico.
5. **Comparación de algoritmos y decisión final:** Se evaluaron siete algoritmos (CatBoost, Decision Tree, LightGBM, Regresión Logística Lasso, Naive Bayes,

Random Forest y XGBoost). El mejor AUC fue de `random_forest` (0.6404), seguido de `lightgbm` (0.6384) y `xgboost` (0.6371). El modelo interpretable `decision_tree` se posicionó cuarto con AUC=0.6354, consolidando una alternativa de transparencia cercana al mejor desempeño. La diferencia de apenas 0.0050 puntos entre el modelo de mayor discriminación y el más interpretable representa un trade-off aceptable para entornos clínicos donde la transparencia algorítmica facilita la adopción.

6. **Trade-off clínico en el punto operativo:** Bajo priorización de sensibilidad, el modelo `random_forest` operó con umbral óptimo de 0.38, recall de 0.8196 y especificidad de 0.3567. Esto implica una tasa de falsos positivos de aproximadamente 64.33 %, por lo que el riesgo de fatiga de alertas debe gestionarse en implementación clínica [17]. La sensibilidad del 81.96 % significa que el modelo detecta correctamente la mayoría de los casos de shock verdadero, aunque a costa de un número considerable de falsas alarmas que podrían generar intervención innecesaria.
7. **Interpretabilidad como requisito de adopción:** Aunque `random_forest` fue el modelo de mayor discriminación, `decision_tree` ofrece mayor transparencia para discusión clínica. El árbol final completo se documenta en anexos como soporte de trazabilidad del modelo. La interpretabilidad no es un lujo sino un requisito para la adopción clínica: los profesionales de salud necesitan comprender las razones detrás de cada predicción para confiar y actuar en consecuencia.

7.2. Conclusiones sobre la arquitectura de software

La arquitectura de software también dejó varias conclusiones relevantes para el desarrollo del proyecto:

1. **Adecuación a la escala del problema:** La decisión de no depender de una plataforma de procesamiento distribuido, como Apache Spark, permitió mantener el proyecto ajustado a la escala real de los datos y evitó introducir complejidad innecesaria en la etapa de modelado.
2. **Orquestación y repetibilidad:** La incorporación de Apache Airflow como orquestador facilitó la ejecución secuencial de las tareas, el seguimiento de cada experimento y la repetibilidad de los procesos. Esto fue especialmente útil para administrar los cinco experimentos de la tesis, ya que cada uno reutilizó la misma base de preparación, entrenamiento y evaluación sin duplicar lógica en scripts independientes.
3. **Desacoplamiento entre configuración y ejecución:** El uso combinado del patrón *Factory* y de archivos YAML permitió separar la definición de modelos de

su ejecución. En la práctica, esto hizo posible cambiar algoritmos, ajustar hiperparámetros y activar o desactivar componentes del flujo mediante configuración, sin modificar la estructura principal del código. Esta decisión redujo errores de mantenimiento y favoreció la comparación sistemática entre modelos.

4. **Organización y reutilización de resultados:** La organización automática de reportes y la interfaz de usuario para editar configuraciones facilitaron el trabajo diario del proyecto y dejaron una base reutilizable para futuras iteraciones. En conjunto, la arquitectura permitió sostener una línea de experimentación clara, trazable y adaptable, lo cual fue determinante para llegar a resultados consistentes en la comparación de modelos.

7.3. Trabajo futuro

1. **Incorporación de variables temporales:** Integrar señales vitales continuas (frecuencia cardíaca, presión arterial, saturación de oxígeno) para capturar tendencias y patrones de deterioro hemodinámico durante el procedimiento quirúrgico y las primeras horas postoperatorias.
2. **Modelos de series temporales:** Dado que el shock hemorrágico es un proceso evolutivo y no un evento estático, explorar arquitecturas como LSTM (Long Short-Term Memory) o Transformers permitiría modelar la evolución temporal del estado del paciente durante y después de la cirugía. Estos modelos son especialmente adecuados para datos secuenciales donde el orden temporal contiene información relevante.
3. **Optimización de umbral dinámico:** Investigar umbrales adaptativos que ajusten la sensibilidad según el contexto clínico (tipo de cirugía, perfil de riesgo del paciente) para reducir la fatiga de alertas sin comprometer la detección de casos críticos. Un umbral dinámico podría calibrar la sensibilidad en función del riesgo basal del paciente, priorizando sensibilidad en perfiles de alto riesgo y aceptando mayor especificidad en pacientes de bajo riesgo.
4. **Validación prospectiva:** Implementar un estudio prospectivo para evaluar el rendimiento del modelo en condiciones clínicas reales y medir el impacto en los tiempos de respuesta del equipo médico. La validación prospectiva constituye el estándar de oro para evaluar la utilidad clínica real de un modelo predictivo.
5. **Integración con sistemas hospitalarios:** Desarrollar la interfaz de integración con los sistemas de información quirúrgica de la FVL para alertas en tiempo real, incluyendo capacitación al personal sobre cómo interpretar y actuar ante las alertas. La interfaz Streamlit desarrollada constituye un prototipo funcional que puede extenderse hacia una solución de producción.

6. **Ampliación del dataset:** Colaborar con otras instituciones para aumentar el tamaño y diversidad del conjunto de datos, mejorando la generalización del modelo y permitiendo técnicas más avanzadas. Un dataset multicéntrico permitiría evaluar y mitigar sesgos de población específicos de la FVL.

Anexos

Árbol de problemas

Problema Principal:

Detección tardía del riesgo de shock hemorrágico en pacientes sometidos a cirugía mayor no cardíaca postoperatoria

Causas:

- **Causa 1: Dependencia exclusiva de la experiencia médica**
 - Sub-causa 1: Variabilidad en la interpretación clínica
 - Sub-sub-causa 1: Diferencias en criterios diagnósticos entre profesionales
 - Sub-sub-causa 2: Falta de protocolos estandarizados de evaluación
 - Sub-causa 2: Sesgos cognitivos en la toma de decisiones clínicas
 - Sub-causa 3: Limitaciones humanas en el monitoreo continuo
 - Sub-sub-causa 1: Fatiga del personal médico durante procedimientos prolongados
 - Sub-sub-causa 2: Dificultad para detectar cambios sutiles en signos vitales
 - Sub-sub-causa 3: Sobrecarga de información durante situaciones críticas
- **Causa 2: Protocolos clínicos no actualizados**
 - Sub-causa 1: Enfoque reactivo en lugar de predictivo
 - Sub-causa 2: Criterios diagnósticos basados en manifestaciones tardías
 - Sub-causa 3: No consideración de factores de riesgo individuales
- **Causa 3: Escasa personalización según características del paciente**
 - Sub-causa 1: Ignorancia de comorbilidades específicas
 - Sub-causa 2: Falta de adaptación a características demográficas

Efectos:

- **Efecto 1: Aumento de la mortalidad postoperatoria**
 - Sub-efecto 1: Muertes por hemorragia no controlada

- Sub-efecto 2: Daño irreversible a órganos por hipoperfusión prolongada
- Sub-efecto 3: Mayor riesgo de infecciones postoperatorias
- Sub-efecto 4: Falla multiorgánica por manejo tardío
- **Efecto 2: Mayor necesidad de transfusiones sanguíneas**
 - Sub-efecto 1: Uso ineficiente de recursos sanguíneos
 - Sub-sub-efecto 1: Transfusiones reactivas en lugar de preventivas
 - Sub-sub-efecto 2: Escasez de hemoderivados en momentos críticos
 - Sub-sub-efecto 3: Mayor riesgo de reacciones adversas
 - Sub-efecto 2: Complicaciones asociadas a transfusiones
 - Sub-sub-efecto 1: Sobrecarga circulatoria
 - Sub-sub-efecto 2: Reacciones inmunológicas
 - Sub-sub-efecto 3: Mayor riesgo de infecciones
- **Efecto 3: Incremento de complicaciones postoperatorias**
 - Sub-efecto 1: Daño orgánico por hipoperfusión prolongada
 - Sub-sub-efecto 1: Insuficiencia renal aguda
 - Sub-sub-efecto 2: Daño cerebral por hipoxia
 - Sub-sub-efecto 3: Necrosis intestinal
 - Sub-efecto 2: Prolongación de la recuperación
 - Sub-sub-efecto 1: Necesidad de cirugías adicionales correctivas
 - Sub-sub-efecto 2: Rehabilitación más compleja y prolongada
- **Efecto 4: Impacto económico y en recursos hospitalarios**
 - Sub-efecto 1: Aumento de los costos médicos
 - Sub-sub-efecto 1: Mayor duración de la estancia hospitalaria
 - Sub-sub-efecto 2: Uso excesivo de recursos críticos (UCI, sangre, medicamentos)
 - Sub-sub-efecto 3: Costos adicionales por manejo de complicaciones
 - Sub-efecto 2: Saturación de recursos hospitalarios

Cronograma




Figura 35: Cronograma detallado del Proyecto de Grado en Inteligencia Artificial, elaborado mediante TeamGantt

Análisis de Participación

- Gustavo Adolfo Cruz Suarez – Médico Anestesiólogo (FVL)
- Daniela Hincapié – Médico Centro de Investigaciones Clínicas (FVL)
- Felipe Ocampo Osorio – Director de IA (FVL)

Anexo tecnico de metricas por modelo

Este anexo consolida metricas detalladas por modelo y experimento, variables descartadas en pruning, hiperparametros optimos de la fase 5, importancia de caracteristicas en fases 2 y 3, y el arbol de decision final.

Experimento 1 (Baseline): metricas detalladas

Tabla 14: Resumen de discriminacion y calibracion - Experimento 1 (Baseline)

Modelo	AUC-ROC CV	Brier	Threshold
catboost	0.6153	0.2134	0.2200
decision_tree	0.5557	0.3836	0.2000
lightgbm	0.5943	0.2394	0.2000
logistic_regression_lasso	0.6055	0.2122	0.2500
naive_bayes	0.5713	0.5993	0.2500
random_forest	0.5856	0.2444	0.2000
xgboost	0.5950	0.2476	0.2000

Tabla 15: Resumen de punto operativo - Experimento 1 (Baseline)

Modelo	Recall	Specificity	F1	Kappa
catboost	0.8090	0.2991	0.4911	0.0806
decision_tree	0.4111	0.6909	0.3995	0.1002
lightgbm	0.6897	0.4330	0.4771	0.0993
logistic_regression_lasso	0.8196	0.2991	0.4960	0.0883
naive_bayes	0.8594	0.1564	0.4713	0.0111
random_forest	0.7056	0.4093	0.4770	0.0917
xgboost	0.7003	0.4606	0.4925	0.1315

Experimento 2 (Agregaciones): metricas detalladas

Tabla 16: Resumen de discriminacion y calibracion - Experimento 2 (Agregaciones)

Modelo	AUC-ROC CV	Brier	Threshold
catboost	0.6192	0.2133	0.2200
decision_tree	0.5592	0.3816	0.2000
lightgbm	0.5995	0.2388	0.2000
logistic_regression_lasso	0.6055	0.2122	0.2500
naive_bayes	0.5657	0.5986	0.5000
random_forest	0.5907	0.2421	0.5000
xgboost	0.6045	0.2453	0.2000

Tabla 17: Resumen de punto operativo - Experimento 2 (Agregaciones)

Modelo	Recall	Specificity	F1	Kappa
catboost	0.8143	0.3091	0.4939	0.0854
decision_tree	0.4058	0.6921	0.3943	0.0964
lightgbm	0.7029	0.4318	0.4813	0.1045
logistic_regression_lasso	0.8064	0.2929	0.4880	0.0738
naive_bayes	–	–	–	–
random_forest	–	–	–	–
xgboost	0.6843	0.4631	0.4817	0.1211

Experimento 3 (Categorizaciones): metricas detalladas

Tabla 18: Resumen de discriminacion y calibracion - Experimento 3 (Categorizaciones)

Modelo	AUC-ROC CV	Brier	Threshold
catboost	0.6134	0.2148	0.2200
decision_tree	0.5570	0.3836	0.2000
lightgbm	0.5934	0.2392	0.2000
logistic_regression_lasso	0.6037	0.2125	0.2500
naive_bayes	0.5741	0.5972	0.2900
random_forest	0.5813	0.2452	0.2000
xgboost	0.5950	0.2476	0.2000

Tabla 19: Resumen de punto operativo - Experimento 3 (Categorizaciones)

Modelo	Recall	Specificity	F1	Kappa
catboost	0.8143	0.2979	0.4932	0.0835
decision_tree	0.4058	0.7046	0.3995	0.1095
lightgbm	0.7003	0.4293	0.4813	0.1045
logistic_regression_lasso	0.8090	0.3004	0.4915	0.0816
naive_bayes	0.8568	0.1640	0.4722	0.0145
random_forest	0.7109	0.4005	0.4794	0.0947
xgboost	0.7003	0.4606	0.4925	0.1315

Experimento 4 (Pruning): metricas detalladas

Tabla 20: Resumen de discriminacion y calibracion - Experimento 4 (Pruning)

Modelo	AUC-ROC CV	Brier	Threshold
catboost	0.6237	0.2126	0.2300
decision_tree	0.5598	0.3795	0.2000
lightgbm	0.5995	0.2388	0.2000
logistic_regression_lasso	0.6067	0.2111	0.2500
naive_bayes	0.5699	0.2649	0.2000
random_forest	0.5847	0.2438	0.2000
xgboost	0.6038	0.2462	0.2000

Tabla 21: Resumen de punto operativo - Experimento 4 (Pruning)

Modelo	Recall	Specificity	F1	Kappa
catboost	0.8011	0.3342	0.4996	0.1024
decision_tree	0.4271	0.6859	0.4081	0.1102
lightgbm	0.7029	0.4418	0.4863	0.1173
logistic_regression_lasso	0.8249	0.2628	0.4988	0.0883
naive_bayes	0.6711	0.3917	0.4534	0.0501
random_forest	0.7162	0.4043	0.4809	0.0957
xgboost	0.6897	0.4719	0.4906	0.1329

Experimento 5 (Hiperparametros): metricas detalladas

Tabla 22: Resumen de discriminacion y calibracion - Experimento 5 (Hiperparametros)

Modelo	AUC-ROC CV	Brier	Threshold
catboost	0.6215	0.2083	0.2400
decision_tree	0.6354	0.2117	0.2200
lightgbm	0.6384	0.2063	0.2400
logistic_regression_lasso	0.6068	0.2396	0.4200
naive_bayes	0.5707	0.2598	0.2000
random_forest	0.6404	0.2289	0.3800
xgboost	0.6371	0.2070	0.2400

Tabla 23: Resumen de punto operativo - Experimento 5 (Hiperparametros)

Modelo	Recall	Specificity	F1	Kappa
catboost	0.8488	0.2716	0.5004	0.0880
decision_tree	0.8568	0.3154	0.5180	0.1280
lightgbm	0.8700	0.2278	0.4962	0.0700
logistic_regression_lasso	0.8037	0.3191	0.4951	0.0924
naive_bayes	0.6897	0.3554	0.4514	0.0353
random_forest	0.8196	0.3567	0.5150	0.1344
xgboost	0.8594	0.3004	0.5143	0.1180

Experimento 5 (Hiperparametros): calibracion comparativa

La calibracion probabilistica mide la concordancia entre las probabilidades predichas y las frecuencias observadas. La metrica Brier (rango 0-1, menor es mejor) cuantifica el error cuadratico medio entre predicciones y outcomes binarios. Valores cercanos a 0 indican predicciones bien calibradas.

Tabla 24: Metricas de calibracion - Top 4 modelos Experimento 5

Modelo	Brier Score	Interpretacion
xgboost	0.2070	Mejor calibracion (error cuadratico bajo)
lightgbm	0.2063	Calibracion optima
catboost	0.2083	Calibracion competitiva
decision_tree	0.2117	Calibracion aceptable
random_forest	0.2289	Calibracion moderada

Analisis: Aunque random_forest lidera en AUC-ROC (0.6404), lightgbm y xgboost presentan mejor calibracion probabilistica (Brier $\approx$ 0.206-0.207). Decision_tree

mantiene calibracion aceptable (0.2117) con maxima interpretabilidad. El trade-off entre discriminacion (AUC) y calibracion (Brier) sugiere que random_forest prioriza separacion de clases sobre precision probabilistica.

Experimento 5 (Hiperparametros): parametros optimos por modelo

Tabla 25: Parametros optimos (optimized_params) en Experimento 5

Modelo	Parametros optimos
catboost	verbose=0, iterations=100, learning_rate=0.01, depth=5, l2_leaf_reg=1, auto_class_weights=None
decision_tree	max_depth=7, min_samples_split=10, min_samples_leaf=20, criterion=gini, class_weight=None
lightgbm	verbosity=-1, n_estimators=100, learning_rate=0.01, max_depth=5, num_leaves=31, min_child_samples=20, subsample=1, colsample_bytree=1, scale_pos_weight=2
logistic_regression_lasso	penalty=l2, solver=lbfgs, max_iter=10000, C=0.001, class_weight=None
naive_bayes	var_smoothing=0.1
random_forest	n_jobs=-1, n_estimators=300, max_depth=5, min_samples_split=10, min_samples_leaf=20, max_features=None, class_weight=balanced
xgboost	verbosity=0, n_estimators=500, max_depth=7, learning_rate=0.01, subsample=1, colsample_bytree=0.6, scale_pos_weight=3, gamma=5, reg_alpha=0, reg_lambda=1

Importancia de características por modelo (Experimentos 2, 3 y 5)

Para cada modelo se reporta el top 3 de importancia cuando el artefacto esta disponible en plot_metadata.json. En modelos sin importancia embebida se marca como No aplica.

Tabla 26: Top 3 de importancia de características en Experimentos 2, 3 y 5

Experimento	Modelo	Top 3 características (pct)
Experimento 2 (Agregaciones)	catboost	HB_PREQX (26.83 %), EDAD2 (21.34 %), EDAD (20.75 %)
Experimento 2 (Agregaciones)	decision_tree	HB_PREQX (35.30 %), EDAD (22.49 %), EDAD2 (16.24 %)
Experimento 2 (Agregaciones)	lightgbm	HB_PREQX (44.60 %), EDAD (39.07 %), GENERO (3.43 %)
Experimento 2 (Agregaciones)	random_forest	HB_PREQX (40.91 %), EDAD (20.64 %), EDAD2 (19.43 %)
Experimento 2 (Agregaciones)	xgboost	SANGRADO_MAYOR (26.68 %), HIPERTENSION (7.11 %), ACT_FISICA_METS (6.08 %)
Experimento 3 (Categorizaciones)	catboost	EDAD (36.92 %), HB_PREQX (24.89 %), SANGRADO_MAYOR (9.03 %)
Experimento 3 (Categorizaciones)	decision_tree	EDAD (38.69 %), HB_PREQX (36.01 %), GENERO (5.87 %)
Experimento 3 (Categorizaciones)	lightgbm	HB_PREQX (45.03 %), EDAD (42.43 %), GENERO (3.37 %)
Experimento 3 (Categorizaciones)	random_forest	EDAD (38.72 %), HB_PREQX (36.36 %), SANGRADO_MAYOR (4.20 %)
Experimento 3 (Categorizaciones)	xgboost	SANGRADO_MAYOR (28.88 %), CANCER_ACTIVIVO (9.05 %), HIPOTIROIDISMO (7.64 %)
Experimento 5 (Hiperparametros)	random_forest	EDAD (52.71 %), HB_PREQX (27.93 %), SANGRADO_MAYOR (15.36 %)
Experimento 5 (Hiperparametros)	decision_tree	EDAD (49.66 %), HB_PREQX (24.51 %), SANGRADO_MAYOR (24.19 %)
Experimento 5 (Hiperparametros)	lightgbm	EDAD (52.25 %), HB_PREQX (36.59 %), SANGRADO_MAYOR (7.39 %)
Experimento 5 (Hiperparametros)	xgboost	SANGRADO_MAYOR (30.66 %), EDAD (11.22 %), CARGA_CARDIOVASCULAR (8.33 %)

Referencias

- [1] F. G. Bonanno, “Management of Hemorrhagic Shock: Physiology Approach, Timing and Strategies,” Jan. 01, 2023, MDPI. doi: 10.3390/jcm12010260.
- [2] L. J. Terceros-Almanza et al., “Prediction of massive bleeding. Shock index and modified shock index,” *Medicina Intensiva (English Edition)*, vol. 41, no. 9, pp. 532–538, Dec. 2017, doi: 10.1016/J.MEDINE.2017.10.003.
- [3] V. Moll, A. K. Khanna, and P. Mathur, “Artificial intelligence for the prediction of postoperative complications in the critically ill,” *Critical Care Science*, vol. 37, p. e20250025, 2025, doi: 10.62675/2965-2774.20250025.
- [4] N. Hooper and T. J. Armstrong, “Hemorrhagic Shock,” *StatPearls*, Sep. 2022, Accessed: Sep. 07, 2025. [Online]. Available: <https://www.ncbi.nlm.nih.gov/books/NBK470382/>
- [5] G. James, D. Witten, T. Hastie, R. Tibshirani, and J. Taylor, “An Introduction to Statistical Learning,” 2023, doi: 10.1007/978-3-031-38747-0.
- [6] G. S. Collins, J. B. Reitsma, D. G. Altman, and K. G. M. Moons, “Transparent reporting of a multivariable prediction model for individual prognosis or diagnosis (TRIPOD): The TRIPOD statement,” *BMJ (Online)*, vol. 350, Jan. 2015, doi: 10.1136/BMJ.G7594.
- [7] Z. Zhang et al., “Machine learning model for postpancreaticoduodenectomy haemorrhage prediction: an international multicentre cohort study,” *BMJ Open*, vol. 15, no. 7, p. e096147, Jul. 2025, doi: 10.1136/BMJOPEN-2024-096147.
- [8] X. Cong, X. Zou, R. Zhu, Y. Li, L. Liu, and J. Zhang, “Development and validation of a machine learning-based model for perioperative stroke prediction in noncardiac, nonvascular, and nonneurosurgical patients,” *Front Physiol*, vol. 16, p. 1624898, 2025, doi: 10.3389/FPHYS.2025.1624898/FULL.
- [9] A. Lucas, A. T. Williams, and P. Cabrales, “Prediction of Recovery from Severe Hemorrhagic Shock Using Logistic Regression,” *IEEE J Transl Eng Health Med*, vol. 7, 2019, doi: 10.1109/JTEHM.2019.2924011.
- [10] Ncr and J. Clinton, “CRISP-DM 1.0 Step-by-step data mining guide,” 1999.
- [11] S. B. Piasta and L. M. Justice, “Cohen’s d Statistic,” *Encyclopedia of Research Design*, pp. 181–185, May 2010, doi: 10.4135/9781412961288.
- [12] R. L. Wasserstein and N. A. Lazar, “The ASA Statement on p-Values: Context, Process, and Purpose,” *Am Stat*, vol. 70, no. 2, pp. 129–133, Apr. 2016, doi: 10.1080/00031305.2016.1154108.

- [13] M. Allen, “Cramér’s V,” *The SAGE Encyclopedia of Communication Research Methods*, Jul. 2017, doi: 10.4135/9781483381411.N107.
- [14] J. W. Cannon, “Hemorrhagic Shock,” *The New England Journal of Medicine*, vol. 378, no. 4, pp. 370–379, 2018, doi: 10.1056/NEJMra1705649.
- [15] J. Ma, P. Dhiman, C. Qi, G. Bullock, M. van Smeden, R. D. Riley, and G. S. Collins, “Poor handling of continuous predictors in clinical prediction models using logistic regression: A systematic review,” *Journal of Clinical Epidemiology*, vol. 161, pp. 140–151, 2023, doi: 10.1016/j.jclinepi.2023.07.012.
- [16] R. Pal et al., “ShockModes: A Multimodal Model for Prognosticating Intensive Care Outcomes from Physician Notes and Vitals,” *medRxiv*, 2022, doi: 10.1101/2022.12.16.22283559.
- [17] E. W. Steyerberg, H. Uno, J. P. A. Ioannidis, B. van Calster, and collaborators, “Clinical prediction models cannot be trusted when common modeling approaches are followed,” *Journal of Clinical Epidemiology*, vol. 98, pp. 133–143, 2018, doi: 10.1016/j.jclinepi.2018.02.008.